ERRATA · RELATÓRIO DE ACOMPANHAMENTO V2 (07/10/2026)

Errata do Relatório V2 – Classificação de Glitches do LIGO com CNNs

Projeto 3 – Ondas Gravitacionais · PIC Astronomia · 17 de outubro de 2026

1. Resumo

Esta errata corrige o Relatório V2, que permanece publicado sem alterações como registro histórico. Três problemas da linha v9 do código – dois apontados pela revisão da linha gwproject 2.0 (PR #2, Daniel Tedesco) e um terceiro encontrado ao quantificá-los – afetam resultados do V2:

1. **Painel vazio repetido nos dados Gravity Spy:** a mesma imagem vazia aparece 161 vezes, com 8 rótulos diferentes, distribuída entre treino, validação e teste.
2. **Limiar OOD calibrado nas mesmas amostras do ajuste:** a referência de Mahalanobis foi ajustada e teve seus quantis calculados nas mesmas 1.200 imagens de validação.
3. **Mistura de modelos no escore OOD do ensemble:** a distância foi calculada com os embeddings do seed 101 e comparada com a referência construída com o seed 42.

> **Principal consequência.** A afirmação de que "todos os 150 canais ficam acima do limiar de detecção fora de distribuição (OOD)" não se sustenta. Com o cálculo consistente (seed 42, referência ajustada no treino e calibrada na validação), **60 dos 150 canais** excedem algum limiar q99 com a renderização Gravity Spy, e 90 ficam dentro dos dois limiares.

Todos os números desta errata foram medidos com os modelos e o código da linha v9 (branch `v9`), em precisão fp32. Por isso podem diferir na terceira casa decimal dos valores do V2, obtidos com precisão mista (AMP).

2. Painel vazio repetido nos dados Gravity Spy

Ao agrupar as 7.966 imagens harmonizadas por conteúdo idêntico de pixels, o maior grupo tem **161 cópias de um painel vazio** (cinza quase uniforme, mediana 30, máximo 66), provavelmente uma renderização do Gravity Spy que falhou. Os rótulos dessas cópias são:

Rótulo	Treino	Validação	Teste
Extremely_Loud	93	20	18
No_Glitch	8	2	1
Paired_Doves	5	1	2
Blip, Koi_Fish, Low_Frequency_Burst, None_of_the_Above, Whistle	11	0	0
Total	**117**	**23**	**21**

A rede aprendeu "painel vazio = Extremely_Loud", o rótulo da maioria: **as 5 seeds classificam as 21 cópias de teste como Extremely_Loud**. Sem essas cópias, o conjunto de teste fica com 1.158 imagens, o mesmo número obtido pela linha 2.0 após o controle de qualidade.

Métrica no teste (média ± desvio, 5 seeds)	Com o painel vazio (1.179)	Sem o painel vazio (1.158)
Macro-F1	0,856 ± 0,007	0,871 ± 0,007
Acurácia balanceada	0,844 ± 0,009	0,867 ± 0,009
Acurácia	0,909 ± 0,004	0,910 ± 0,004

Efeito no V2: a confusão "Paired_Doves → Extremely_Loud (2 de 4)" destacada na Figura 1 e no Anexo C corresponde exatamente às 2 amostras de teste de Paired_Doves que são o painel vazio; não é um erro de morfologia da rede. As métricas de teste do V2 estão levemente subestimadas por essas cópias, mas os modelos também foram treinados com 117 delas, o que só se resolve com novo treino. A linha 2.0 remove esses painéis por controle de qualidade e obtém macro-F1 de 0,945.

3. Limiar OOD calibrado nas mesmas amostras do ajuste

O script `build_ood_reference.py` da linha v9 ajusta as médias e a matriz de precisão de Mahalanobis nas 1.200 imagens de validação e calcula os limiares q95/q99 **nessas mesmas imagens**. Em 512 dimensões, as distâncias medidas nas próprias amostras de ajuste ficam subestimadas, e o limiar sai baixo demais.

Imagens de teste do Gravity Spy acima do q99 (seed 42; esperado ≈ 1%)	Resultado
Referência do V2 (ajuste e quantis na validação; q99 = 638)	**42,3%**
Referência corrigida: Mahalanobis ajustado no treino, q99 calibrado na validação (q99 = 1.213)	1,4%
Energia, q99 calibrado na validação	0,9%

Com a referência do V2, quase metade das imagens comuns do próprio Gravity Spy seria declarada "fora do domínio". A referência corrigida reproduz a taxa nominal.

4. Mistura de modelos no escore OOD do ensemble

O script `classify_catalog_qgrams_ensemble.py` calcula a distância de Mahalanobis com os embeddings do primeiro modelo da lista de checkpoints, que no V2 era o **seed 101**, mas a referência OOD foi construída com o **seed 42**. Redes treinadas de forma independente têm espaços de embeddings não alinhados, e a distância resultante não tem significado. É a origem das medianas de 18.424, 11.670 e 2.228 do V2, muito acima do limiar de 638.

150 canais GWTC, renderização Gravity Spy	Mediana da distância	Canais acima do q99
V2 (embeddings do seed 101, referência do seed 42)	2.228	150 de 150
Seed 42 consistente, referência do V2 (problema da seção 3)	853	144 de 150
Seed 42 consistente, referência corrigida – Mahalanobis	773	**2 de 150**
Seed 42 consistente, referência corrigida – energia	–	59 de 150
Seed 42 consistente, referência corrigida – algum dos dois	–	**60 de 150**

Com o cálculo consistente, a distância de Mahalanobis dos Q-grams reais fica, na mediana, abaixo do limiar, e a rejeição passa a vir quase toda do escore de energia. É o mesmo padrão que a linha 2.0 obteve nos 475 canais de 218 eventos (Mahalanobis acima de q99 cai de 475 para 49 e energia sobe de 0 para 227 com a renderização Gravity Spy).

5. Afirmações do V2 corrigidas

Onde / afirmação no V2	Correção
Resumo e Conclusão: “todos os 150 canais ainda ficam acima do limiar OOD”; “a transferência não está validada porque todos os canais continuam fora do domínio”	Com o cálculo consistente, 60 de 150 canais (40%) excedem algum limiar q99, e 90 ficam dentro dos dois, com um único modelo (seed 42). A transferência continua não validada, mas pelos motivos da seção 6, e não por rejeição universal.
Seção 6.3, tabela: medianas de Mahalanobis 18.424 / 11.670 / 2.228 e “150 / 150 / 150 canais acima do q99”	Valores calculados com modelos misturados e limiar subestimado; não devem ser usados. A tendência (a renderização Gravity Spy aproxima os dados reais do domínio de treino) se mantém.
Figura 6 (distância de Mahalanobis nas três renderizações)	Inválida pelos motivos das seções 3 e 4.
Seção 6.1 e Anexo C: confusão Paired_Doves → Extremely_Loud (2 de 4)	São as 2 cópias do painel vazio no teste, não um erro de morfologia.
Seção 6.1: macro-F1 0,856 ± 0,006	Valor correto para o conjunto de teste com as cópias; sem elas, 0,871 ± 0,007. Os modelos foram treinados com o painel vazio.
Seção 8 (limitações) e Seção 10 (próximos passos): “diferença de domínio persistente”, “fechar a diferença de domínio”	A diferença existe, mas é bem menor que a relatada; os próximos passos devem partir dos escores corrigidos e de uma referência por modelo.

6. O que permanece válido

- As três correções de pipeline do V2: orientação dos Q-grams, cores do Grad-CAM e renderização na escala Gravity Spy.
- O Grad-CAM concentra a atenção no próprio transiente; a “Detecção por Silhueta” do V1 continua descartada.
- O controle positivo: os eventos mais intensos são classificados como Chirp com confiança acima de 0,95 (a classificação do ensemble não depende do escore OOD).
- A revogação do estudo de caso GW151012 do V1.
- A correção do filtro casado e do espectrograma do kit didático.

Limites desta errata. As medições OOD usam um único modelo (seed 42), treinado com o painel vazio, e uma referência corrigida em vez de uma referência por modelo. Servem para dimensionar os erros do V2, não como resultado final. A análise de referência é a da linha gwproject 2.0 (`VALIDATION_REPORT.md` e `research/RENDERIZADOR_GRAVITY_SPY.md`), que retreina os modelos sem o painel vazio e constrói uma referência OOD por modelo.

7. Reprodutibilidade

Script: `docs/relatorios/fontes/errata_metrics.py`; resultados: `errata_metrics.json` na mesma pasta. O script usa o código e os modelos da branch `v9` e os dados locais do Gravity Spy e dos Q-grams:

```
git worktree add ../GW-v9 v9
python docs/relatorios/fontes/errata_metrics.py ../GW-v9 errata_metrics.json
```

Executado em 17/10/2026, NVIDIA RTX 3060, PyTorch 2.5.1 + CUDA 12.1, fp32. Os problemas 1 e 2 foram identificados na revisão da linha gwproject 2.0 (PR #2); o problema 3 foi encontrado ao quantificá-los.