Plano 1 — “a mesma câmera”: gerar as imagens dos eventos e do treino do mesmo jeito

Projeto 3 – Ondas Gravitacionais · PIC Astronomia · linha gwproject 2.0 · critérios fixados em 26 de outubro de 2026, antes de qualquer resultado

Resumo

O Relatório de Resultados concluiu que a rede neural melhorou, mas ainda não reconhece os eventos reais: os 475 sinais dos 218 eventos são rejeitados como “fora do domínio”. Antes de ensinar a rede a reconhecer ondas gravitacionais (Plano 2), precisamos saber se o **jeito de gerar as imagens** — a nossa “câmera” — é parte do problema. As imagens de treino vêm do Gravity Spy; as dos eventos, do nosso código. Elas diferem na faixa de frequência e na escala de intensidade, e só trocar a escala derrubou as rejeições de 475 para cerca de 250.

Este plano faz duas coisas. Primeiro, **iguala a faixa de frequência**: as imagens de treino são recortadas em 20–512 Hz, a faixa dos eventos, e as 5 seeds são retreinadas. Depois, faz um **teste de fechamento**: baixa do GWOSC o strain público nos horários de glitches que o Gravity Spy já rotulou, gera as imagens com o *nosso* código e verifica se a rede os reconhece. Como a classe verdadeira é conhecida, o teste diz se a câmera funciona antes de olharmos de novo para os eventos.

455 glitches de validação/teste reconstruídos pelo nosso código (17 classes com ≥ 10)	**150** arquivos de O1 baixados do GWOSC, um por vez (até ~19,5 GB, apagados após o uso)	**4** condições: modelos atuais × novos, renderer percentis × Gravity Spy	**≈ 1 dia** de máquina, a maior parte download; ~2 h de GPU para o retreino

1. Por que este é o primeiro passo

Em poucas palavras. Ensinamos a rede com fotos tiradas por uma câmera e testamos com fotos de outra. Se ela não reconhece o teste, não sabemos se o problema é o objeto fotografado ou a câmera. Este plano fotografa objetos *conhecidos* com a nossa câmera.

O resultado atual mistura duas mudanças ao mesmo tempo: mudou a câmera (Gravity Spy → nosso código) e mudou o objeto (glitches → ondas gravitacionais). O parecer científico do professor chama isso de explicações concorrentes E1 (renderer) e E2 (semântica) e propõe o teste decisivo H-R: o mesmo trigger, renderizado por cadeias diferentes. Este plano é a versão prática desse teste. A auditoria do HDF5 oficial mostrou que ele só contém imagens prontas, não strain; por isso reconstruímos a partir do strain público, como o próprio roteiro previa.

Etapa da câmera	Gravity Spy (treino)	Nosso código (eventos)	Neste plano
Dados	64 s a 16 kHz (h(t) online)	32 s a 4 kHz (GWOSC)	mantém o nosso
Transformada Q	Q 4–64, 10–2048 Hz	Q 4–64, 20–512 Hz	treino recortado em **20–512 Hz**
Janela	1 s (uma das 4 vistas)	4 s → 1 s central	igual nos dois
Intensidade	energia 0–25,5, viridis → cinza	percentis (canônico) ou escala Gravity Spy	os dois renderers são testados
Centro	pico do trigger Omicron	tempo GPS do evento	GPS do glitch rotulado

Com a faixa diferente, um chirp de 30–300 Hz fica cerca de 1,6× mais esticado na vertical nas nossas imagens do que nas de treino. A escala de intensidade já foi testada (relatório do renderizador), mas sem a faixa igualada e sem classe verdadeira conhecida.

2. Pergunta, hipótese e critérios

> **Pergunta.** Glitches rotulados, reconstruídos do strain público pela mesma cadeia dos eventos, são reconhecidos pela rede como os painéis oficiais?
> **Hipótese.** Com a faixa de frequência e a escala de intensidade igualadas (condição B1), sim. Com os modelos atuais (A1, A2), não.

Os critérios abaixo estão em `configs/plano1.toml` e foram fixados **antes** de qualquer resultado. Mudá-los depois exige uma nova versão do arquivo e registro neste documento.

Critério	O que mede	Limiar	Onde
C0 — base do modelo novo	macro-F1 médio das 5 seeds no teste oficial (painéis recortados)	≥ 0,85	lote 3
C0 — calibração OOD	pior fração acima do q99 no teste oficial (energy ou Mahalanobis)	≤ 0,02	lote 3
C1 — classificação	macro-F1 da classe do ensemble no conjunto de fechamento	≥ 0,85	lote 4
C1 — classificação	acurácia no conjunto de fechamento	≥ 0,85	lote 4
C2 — "conheço isto?"	fração `reject_ood` no conjunto de fechamento	≤ 0,05	lote 4

- **Condição que decide:** B1 (modelos 20–512 Hz + renderer Gravity Spy). As outras três são comparação.
- **Conjunto que decide:** só glitches dos splits de validação e teste. Os de treino vêm nos mesmos arquivos e são relatados à parte, porque a rede já viu esses triggers como PNG.
- **Macro-F1:** conta só classes com pelo menos 10 amostras; as demais aparecem no relatório por classe, mas não decidem.
- **Incerteza:** intervalos de 95% por bootstrap de *arquivos* (2.000 réplicas, semente 20261026), porque glitches próximos no tempo não são independentes. O veredito usa a estimativa pontual; o intervalo é relatado ao lado.
- **Referência:** no painel oficial, a linha 2.0 tem macro-F1 0,945 e cauda OOD q99 de 0,4–1,4%. O limiar de 0,85 é o mínimo interno do preregistro do professor; 5% de rejeição dá margem à troca de calibração (h(t) online × dados GWOSC).

3. O conjunto de fechamento

Dos 7.807 glitches limpos, 7.209 são de O1. Mas o GWOSC só publica o strain dos trechos em modo científico (lista `{ifo}_DATA`); fora deles o arquivo traz NaN. O Gravity Spy rotulou **1.404 glitches de O1 fora desses trechos**, que não podem ser reconstruídos. Descobrimos isso no primeiro arquivo baixado (141 de 142 glitches em NaN) e a seleção passou a consultar a lista antes de baixar. Também ficam de fora 54 glitches cuja janela de 32 s sai do arquivo.

Os arquivos do GWOSC têm 4.096 s (até 130 MB a 4 kHz). Uma seleção gulosa escolhe 150 arquivos (detector + horário) que cobrem o máximo de classes: cada classe vale log(1 + n) até 40 amostras, então a primeira amostra de uma classe rara pesa mais que a vigésima de uma comum. A cobertura satura em 257 arquivos (615 glitches, até ~33 GB); ficamos com 150, que já dão 17 classes acima de 10 amostras.

Classe	Teste	Validação	Avaliação	Treino (secundário)
Blip	23	18	41	57
Scattered_Light	25	15	40	84
Low_Frequency_Burst	17	23	40	39
Light_Modulation	21	19	40	63
Low_Frequency_Lines	16	18	34	45
Koi_Fish	17	15	32	29
Scratchy	19	11	30	25
Power_Line	15	14	29	11
Whistle	11	14	25	23
Extremely_Loud	12	13	25	35
1400Ripples	8	13	21	52
No_Glitch	12	7	19	6
Repeating_Blips	9	6	15	14
Air_Compressor	8	7	15	4
Tomte	9	6	15	2
Chirp	8	7	15	20
None_of_the_Above	5	9	14	10
Paired_Doves, 1080Lines, Wandering_Line (fora do macro-F1)	2	3	5	9
Violin_Mode, Helix (sem dado público)	0	0	0	0
Total	**237**	**218**	**455**	**528**

Contagens antes do processamento: alguns glitches podem cair em trechos sem dados válidos e serão registrados como rejeitados, nunca descartados em silêncio. 1080Lines tem só 1 glitch em O1 (os demais são de O2 ou de períodos não públicos). Lista exata dos arquivos: `outputs/research/plano1/fechamento/plan_files.csv`.

Cadeia de cada glitch (idêntica à dos eventos)

1. Download arquivo GWOSC de 4.096 s (O1, 4 kHz), com retomada → **2. Recorte** 32 s centrados no GPS do glitch, gravados como os eventos (`raw/<id>/<ifo>.hdf5`) → **3. Q-gram** `gwpy_qtransform_consistent` com `configs/processing.toml` (20–512 Hz) → **4. Limpeza** apaga o arquivo de 130 MB; marca o arquivo como concluído → **5. Classificação** `classify-ensemble` + `closure-report` , como nos eventos

4. As quatro condições

Condição	Modelos	Renderer	Papel
A1_atual_percentile	atuais (painel 10–2048 Hz)	percentis (canônico)	a situação de hoje, com classe conhecida
A2_atual_gravity_spy	atuais	escala Gravity Spy	efeito só da intensidade
B1_banda_gravity_spy	**novos (painel 20–512 Hz)**	**escala Gravity Spy**	**decide o plano** (faixa + intensidade iguais)
B2_banda_percentile	novos	percentis	efeito só da faixa

Comparar A1 → A2 isola a intensidade; A2 → B1 isola a faixa de frequência. Cada condição gera `REPORT.md`, `report.json`, tabela por classe e matriz de confusão (300 DPI).

5. Como ler o resultado

Resultado	Interpretação	Próximo passo
B1 passa em C1 e C2	A câmera está validada: glitches conhecidos são reconhecidos pelo nosso código. A rejeição dos eventos passa a refletir sobretudo a diferença de conteúdo (H-S).	Lote 5 (exploratório) e Plano 2: ensinar a rede o que é uma onda, com esta câmera.
B1 passa em C1, falha em C2	A rede classifica bem, mas o detector OOD acha as imagens estranhas: sobra uma diferença de calibração ou de PSD/whitening.	Investigar por classe e por run antes do Plano 2; comparar energy × Mahalanobis (H-M).
B1 falha em C1	Ainda há diferença de câmera não resolvida (whitening de 32 × 64 s, 4 × 16 kHz, centro do trigger, calibração).	Usar as tabelas por classe para achar o elemento; nova versão do plano.
A1/A2 já passam	A faixa não era o problema (inesperado).	Registrar; o retreino deixa de ser necessário.

> **O que este plano não mostra.** Mesmo com a câmera validada, a rede continua sendo uma classificadora de glitches: só 60 dos 7.807 exemplos de treino são `Chirp` . Passar no Plano 1 não significa que ela identifica ondas gravitacionais; isso depende do Plano 2 (injeções de sinais simulados em ruído real) e não pode ser alegado a partir do lote 5.

6. Execução em lotes

Os scripts estão em `tools/plano1/`. Eles chamam o Python do ambiente `gwproject` diretamente (sem `conda` no terminal), gravam log em `outputs/research/plano1/logs/` e param no primeiro erro. Nenhum deles altera os modelos, a referência OOD ou as saídas canônicas da linha 2.0.

Lote	O que faz	Recursos	Tempo
0 — verificação	ambiente, entradas, espaço em disco (≥ 8 GB) e testes	—	~5 min
1 — conjunto de fechamento	baixa 150 arquivos de O1, recorta 983 glitches, gera os Q-grams, apaga os arquivos; retomável	internet, até ~19,5 GB baixados	4–8 h
2 — linha de base	condições A1 e A2 (modelos atuais)	GPU	~10 min
3 — treino 20–512 Hz	painéis recortados, 5 seeds, referência OOD, controle no teste, critério C0	GPU	~2 h
4 — fechamento e veredito	condições B1 e B2, tabela das 4 condições, veredito de C1/C2	GPU	~10 min
5 — catálogo (exploratório)	só se B1 passar: modelos novos nos 475 canais, pasta própria	GPU	~5 min

Como rodar

No PowerShell, na raiz do repositório. Para rodar tudo de uma vez (lotes 0 a 4):

```
powershell -ExecutionPolicy Bypass -File .\tools\plano1\executar_plano1.ps1
```

Ou lote a lote, por exemplo:

```
powershell -ExecutionPolicy Bypass -File .\tools\plano1\lote0_verificacao.ps1
powershell -ExecutionPolicy Bypass -File .\tools\plano1\lote1_conjunto_fechamento.ps1 -SoPlano   # só
mostra o plano, sem rede
powershell -ExecutionPolicy Bypass -File .\tools\plano1\lote1_conjunto_fechamento.ps1
```

- **Queda de internet no lote 1:** rode o mesmo lote de novo. Cada arquivo concluído deixa um marcador em `fechamento/done/` e não é refeito; o download parcial é retomado.
- **Recomeçar de um lote:** `executar_plano1.ps1 -APartirDe 2`.
- **Modelos já treinados:** `lote3_treino_banda.ps1 -PularTreino`.
- **Outro Python:** todos os lotes aceitam `-Python <caminho do python.exe>`.
- O lote 5 fica fora do `executar_plano1.ps1` de propósito: só se roda depois de ler o veredito.

O que guardar e mandar para revisão

- `outputs/research/plano1/fechamento/summary.json` (cobertura e status de cada glitch);
- `outputs/research/plano1/condicoes/*/fechamento/REPORT.md` e `report.json`;
- `outputs/research/plano1/ood_test_control_band20_512.json` e `models/gravity_spy_band20_512/aggregate_summary.json`;
- os logs de `outputs/research/plano1/logs/`.

7. Limitações conhecidas

- **Calibração.** O Gravity Spy usou o h(t) online; o GWOSC distribui o strain recalibrado. A diferença é pequena, mas pode afastar algumas imagens.
- **Só O1.** Os glitches são de 2015–2016; os eventos vão de O1 a O4a. Passar no fechamento valida a câmera, não a estabilidade entre runs (hipótese H-D do professor).
- **Faixa 20–512 Hz.** Classes de alta frequência (Whistle, 1400Ripples, 1080Lines) perdem parte do que as define. Esperamos queda nelas mesmo com a câmera certa; a tabela por classe mostrará.
- **Classes ausentes ou raras.** Violin_Mode, Helix e Wandering_Line não têm glitches de validação/teste em trecho público de O1; Paired_Doves e 1080Lines ficam abaixo de 10. Essas classes não decidem. No_Glitch tem 19, pouco para a classe mais importante nos eventos fracos.
- **Viés de seleção.** Só entram glitches em modo científico, justamente o regime dos eventos do catálogo; glitches de períodos de comissionamento não são testados.
- **Conhecimento prévio.** O efeito do renderer Gravity Spy nos eventos já foi visto (relatório de 10/10/2026). Por isso a decisão usa glitches com classe conhecida, não os eventos.

8. Arquivos deste plano

Arquivo	Conteúdo
`configs/plano1.toml`	seleção dos arquivos e critérios preregistrados
`src/gwproject/research/closure.py`	seleção gulosa, métricas, bootstrap por arquivo e critérios
`src/gwproject/commands/build_closure_set.py`	comando `gwproject research closure-set` (download, recorte, Q-gram, retomada)
`src/gwproject/commands/closure_report.py`	comando `gwproject research closure-report` (relatório e veredito)
`tests/test_closure.py`	6 testes, incluindo o ciclo completo com um arquivo GWOSC simulado
`tools/plano1/*.ps1`	lotes 0 a 5, funções comuns e execução em sequência

Anexo — Resultados da execução (26/10/2026)

> **Veredito: câmera NÃO validada.** Nenhuma condição atingiu os critérios preregistrados. A condição decisiva (B1) chegou a macro-F1 0,714 e 6,0% de rejeição OOD, contra limiares de 0,85 e 5%.

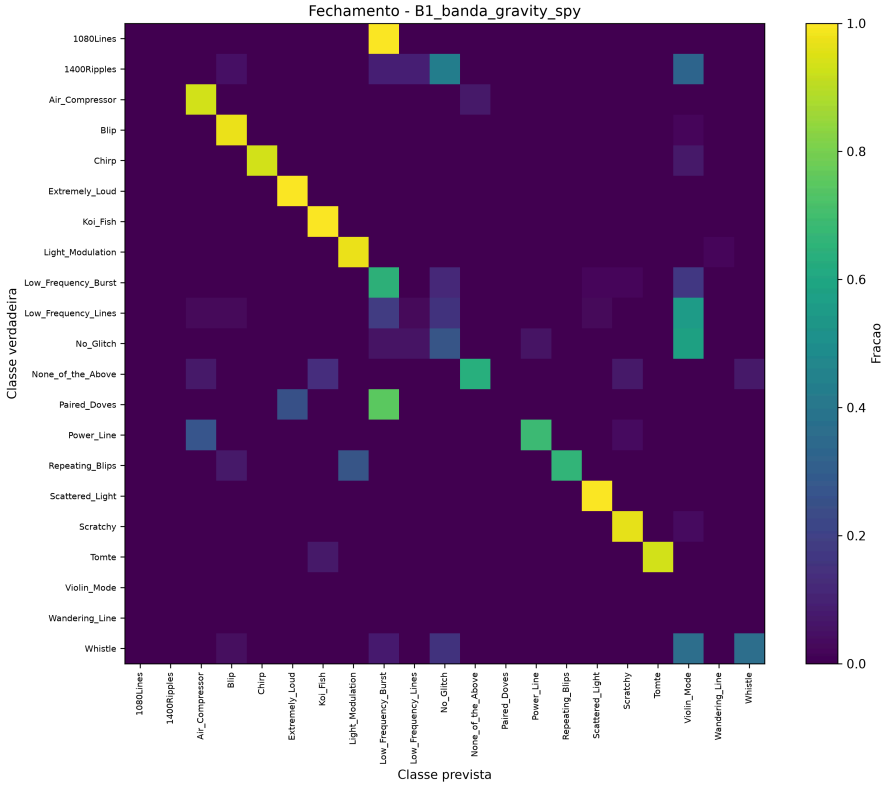
Execução

- **Lote 1:** 150 de 150 arquivos (4 refeitos por queda de conexão com o GWOSC); 983 glitches reconstruídos, todos com Q-gram válido.
- **Exclusão comum às 4 condições:** 17 Q-grams (15 Extremely_Loud, 1 Scattered_Light, 1 Scratchy; só 4 de validação/teste) têm mediana negativa em algum bin de frequência, efeito da interpolação do Q-transform em glitches muito fortes, e o renderer por percentis os recusa. Ficaram 451 glitches de avaliação em 147 arquivos e 17 classes decisivas.
- **C0 atendida, por pouco:** macro-F1 médio de 0,854 no teste oficial (mínimo 0,85) e pior cauda OOD q99 de 0,014 (máximo 0,02). O treino de cada seed acusou F1 < 0,40 em 1400Ripples (sinal em ~1.400 Hz, fora da faixa recortada), como previsto nas limitações.

Condição	Acurácia	Macro-F1 [IC 95%]	reject_ood [IC 95%]	review	in_domain	Veredito
A1 — atuais + percentis	0,086	0,043 [0,023; 0,059]	1,000 [1,00; 1,00]	0,000	0,000	não passou
A2 — atuais + Gravity Spy	0,659	0,642 [0,585; 0,676]	0,341 [0,283; 0,406]	0,483	0,175	não passou
B1 — 20–512 Hz + Gravity Spy	**0,716**	**0,714 [0,660; 0,747]**	**0,060 [0,032; 0,094]**	0,206	0,734	**não passou**
B2 — 20–512 Hz + percentis	0,060	0,022 [0,014; 0,030]	1,000 [1,00; 1,00]	0,000	0,000	não passou

O que os resultados mostram

- **A renderização por percentis é incompatível com a rede.** Com ela, mesmo glitches de classe conhecida são 100% rejeitados e quase nunca classificados corretamente (A1, B2). Isso é forte evidência de que a rejeição total dos 475 canais do catálogo vinha, em boa parte, da câmera, e não só do conteúdo dos eventos (hipótese H-R).
- **Igualar intensidade e faixa ajuda muito, mas não basta.** A1 → A2 (só intensidade) leva o macro-F1 de 0,04 a 0,64; A2 → B1 (faixa) a 0,71 e derruba a rejeição de 34% para 6%.
- **Exploratório (observado depois dos resultados):** em B1 os glitches curtos são reconhecidos quase como no painel oficial — Blip 0,94, Koi_Fish 0,96, Tomte 0,97, Extremely_Loud 0,98 e **Chirp 0,97**. As falhas se concentram em estruturas longas ou estacionárias: Low_Frequency_Lines 0,05, No_Glitch 0,21, Whistle 0,51, quase sempre confundidas com Violin_Mode, além de 1400Ripples 0 (fora da faixa).
- **Hipótese para a próxima versão:** linhas e ruído de fundo dependem fortemente do branqueamento. O Gravity Spy branqueia com 64 s de dados; nossa cadeia, com a janela de 32 s. Esta hipótese não foi testada aqui.



Matriz de confusão normalizada da condição B1 nos 451 glitches de avaliação (ensemble de 5 modelos, 20–512 Hz, escala Gravity Spy). As classes curtas ficam na diagonal; Low_Frequency_Lines, No_Glitch e Whistle migram para Violin_Mode.

Decisões

- O lote 5 (catálogo) **não foi executado**, conforme a regra do plano.
- O renderer canônico continua `percentile` na configuração; este resultado é a evidência a ser discutida antes de qualquer troca.
- Próximo passo: Plano 1, versão 1.1, com branqueamento em 64 s e critérios fixados antes de rodar (documento `Plano_Melhoria_1_1_Branqueamento.pdf`).

Referências: parecer científico e roteiro (`research/PARECER_CIENTIFICO_E_ROTEIRO.md`, hipóteses H-R, H-S, H-M, H-D e Fase 1); renderizador Gravity Spy (`research/RENDERIZADOR_GRAVITY_SPY.md`); parâmetros do Gravity Spy em `gravityspy/utils/utils.py` (github.com/Gravity-Spy/GravitySpy); Relatório de Resultados da linha 2.0.