RELATÓRIO DE RESULTADOS · OUTUBRO DE 2026

Uma rede neural treinada em glitches do LIGO consegue reconhecer os eventos reais de ondas gravitacionais?

Projeto 3 – Ondas Gravitacionais · PIC Astronomia · linha gwproject 2.0, 218 eventos do GWTC-4 · 20 de outubro de 2026

Resumo

Os detectores de ondas gravitacionais registram, além dos sinais astrofísicos, muitos ruídos curtos de origem instrumental, os *glitches*. Treinamos uma rede neural para classificar esses glitches a partir de imagens tempo-frequência do projeto Gravity Spy e a aplicamos aos 218 eventos reais do catálogo GWTC-4. A rede **melhorou de forma clara**: com dados de treino limpos e um protocolo mais rigoroso, sua nota de acerto passou de 0,856 para 0,945. Nos eventos reais, porém, as imagens são diferentes demais das de treino, e a rede as reconhece como estranhas: **todos os 475 sinais são rejeitados como "fora do domínio"**. Desenhar as imagens na mesma escala do treino reduz essa diferença e faz a rede apontar "Chirp" nos eventos mais fortes, mas a maior parte desses casos continua rejeitada. **No momento, a rede neural melhorou, mas ainda não consegue identificar os eventos reais de forma confiável.**

0,945	**475 / 475**	**17 / 475**	**+0,50**
nota de acerto (macro-F1) nos glitches de teste — era 0,856	sinais reais rejeitados como "fora do domínio" (renderização padrão)	sinais que a rede reconhece como familiares com a renderização exploratória	correlação entre a força do evento (SNR) e a fração "Chirp" (exploratório)

1. A pergunta

Em poucas palavras. Ensinamos uma IA a reconhecer "tipos de chiado" do detector. Agora queremos saber se ela também consegue olhar para as ondas gravitacionais de verdade e dizer algo útil sobre elas.

Os interferômetros LIGO (H1, L1) e Virgo (V1) medem deformações do espaço da ordem de 10^{-21}. Nessa sensibilidade, vibrações, falhas eletrônicas e luz espalhada produzem *glitches*, transientes curtos que podem imitar ou esconder um sinal astrofísico. O projeto Gravity Spy reuniu cerca de 8 mil imagens de glitches rotuladas por voluntários em 22 classes, e redes treinadas nelas classificam bem os glitches.

A pergunta deste trabalho é de **validade externa**: um classificador treinado nos painéis do Gravity Spy pode ser aplicado às imagens dos eventos reais do catálogo GWTC-4? Se pudesse, seria uma ferramenta automática para examinar a vizinhança de cada detecção. Se não pudesse, é importante saber por quê, para que ninguém confie nas respostas dele sem verificação.

2. Como o estudo foi feito

1. Dados — Strain dos 218 eventos do GWTC-4, baixado do GWOSC (475 sinais aproveitáveis) →

2. Imagem — Branqueamento e transformada Q: imagem tempo × frequência de 140 × 170 →

3. Rede — 5 ResNet-18 treinadas no Gravity Spy (ensemble); cada uma dá a classe mais provável →

4. "Conheço isto?" — Teste fora de distribuição: a imagem se parece com as de treino? →

5. Explicação — Grad-CAM: onde a rede olhou para decidir

Em poucas palavras. Transformamos o sinal de cada detector numa "foto" do som ao longo do tempo, mostramos a foto a cinco redes neurais e perguntamos duas coisas: que tipo de sinal é, e se a rede já viu algo parecido.

- **Treino.** 7.807 imagens do Gravity Spy, depois de remover 159 painéis vazios repetidos (5.472 para treino, 1.177 para validação e 1.158 para teste). Cinco redes ResNet-18 foram treinadas com pontos de partida aleatórios diferentes (*seeds*), e suas respostas são combinadas (*ensemble*).
- **Classificação forçada.** A rede sempre escolhe uma das 22 classes, mesmo diante de algo que nunca viu. Por isso a classe sozinha não basta.
- **Teste "fora de distribuição" (OOD).** Dois medidores dizem se a imagem é familiar: a **distância de Mahalanobis** (quão longe ela fica das imagens de treino no "espaço interno" da rede) e o **escore de energia** (quão segura a rede está). Cada um tem um limite, o **q99**, calibrado para que só 1% das imagens normais o ultrapassem. A imagem recebe uma de três decisões: *rejeitada* (fora do domínio), *revisar* ou *candidata em domínio*.
- **Renderização.** A forma de converter a energia em tons de cinza. A **padrão** (percentis) estica o contraste de cada imagem; a **exploratória** (escala Gravity Spy) imita a escala das imagens de treino.

3. Resultado 1 — a rede aprendeu bem os glitches

Em poucas palavras. Nas imagens do próprio Gravity Spy, a rede acerta cerca de 96% das vezes, e ficou bem melhor que a versão anterior.

Métrica no conjunto de teste (5 seeds)	Linha v9 (Relatório V2)	Linha 2.0 (atual)
Macro-F1 (acerto equilibrado entre as 22 classes)	0,856	**0,945 ± 0,009**
Acurácia balanceada	0,844	0,946 ± 0,012
Acurácia	0,909	0,965 ± 0,004
Referência simples (regressão linear)	–	0,797

A melhora vem principalmente da limpeza dos dados: um painel vazio aparecia 161 vezes com rótulos diferentes e confundia a rede (errata do Relatório V2). As classes mais beneficiadas foram Paired_Doves, 1400Ripples, Whistle e No_Glitch. As mais difíceis continuam sendo as classes "genéricas", No_Glitch (0,76) e None_of_the_Above (0,77), que por definição reúnem imagens variadas. Duas classes ficaram levemente abaixo da linha v9 (Tomte e None_of_the_Above), dentro da variação entre seeds.

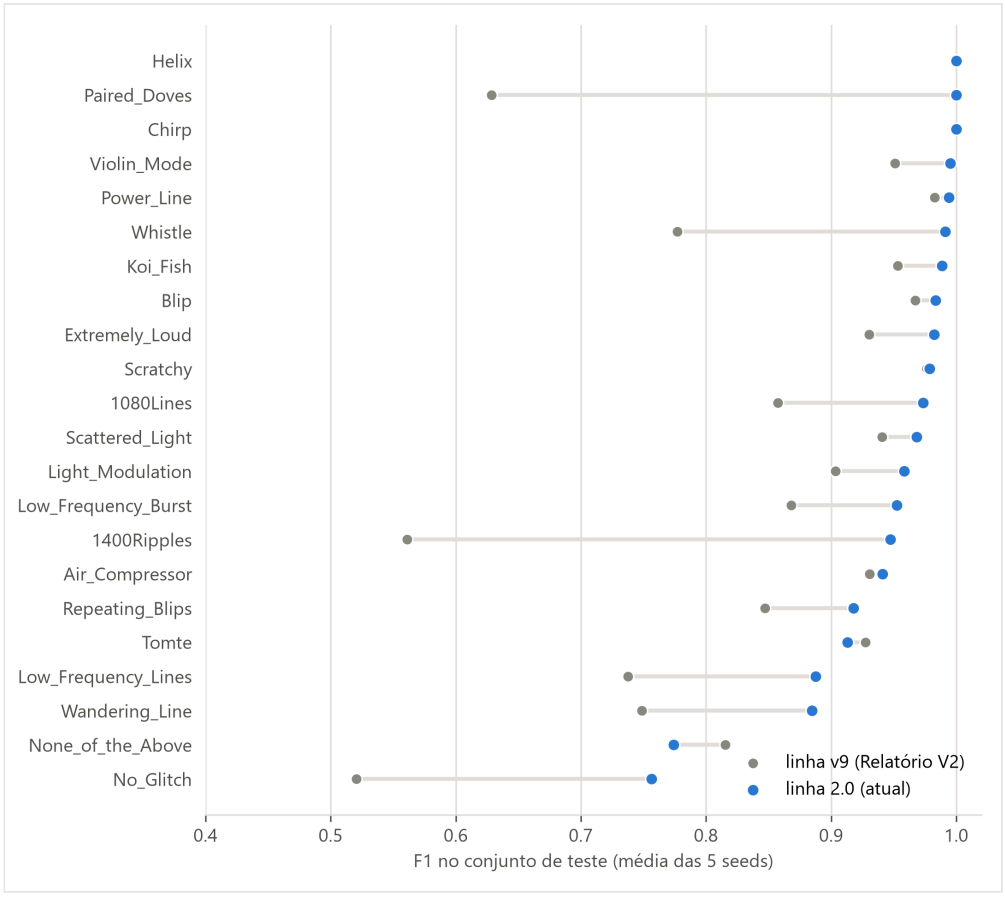


Figura 1 – Acerto (F1) por classe, linha v9 × linha 2.0. Média das 5 seeds no conjunto de teste. O teste da v9 incluía 21 cópias do painel vazio; o da 2.0, não.

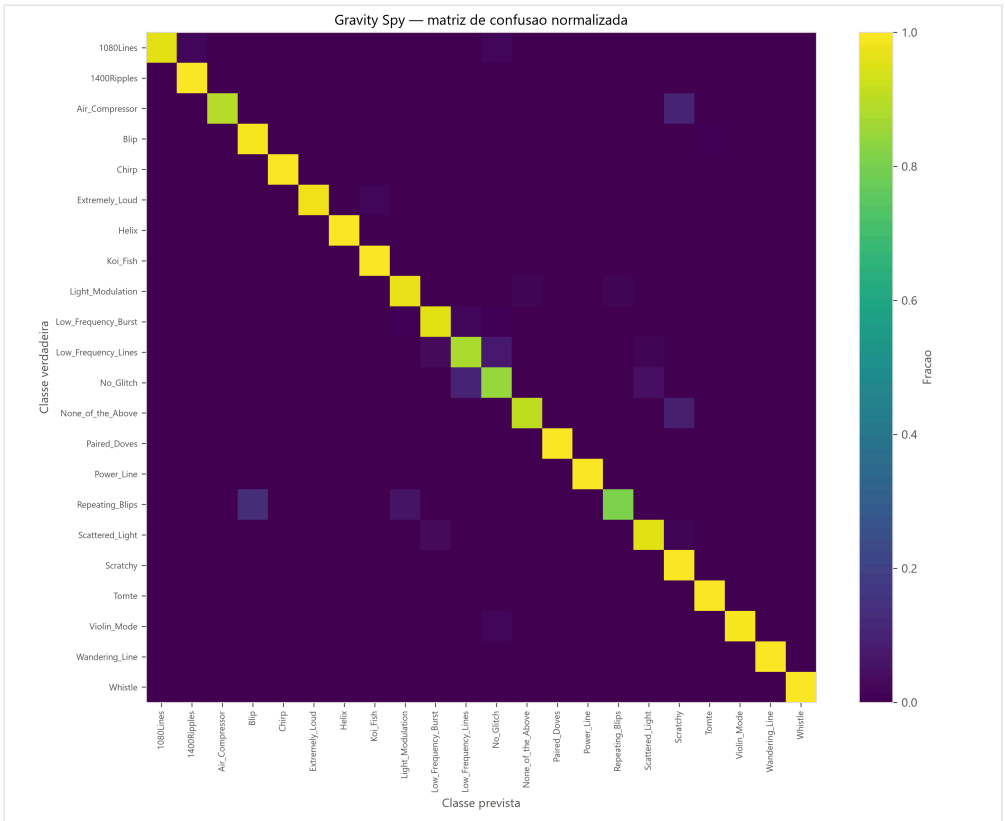


Figura 2 – Matriz de confusão (seed 42). Cada linha mostra, para uma classe verdadeira, a fração de imagens atribuída a cada classe. A diagonal quase completa indica poucos erros; as confusões restantes envolvem No_Glitch e None_of_the_Above.

4. Resultado 2 — nos eventos reais, a rede não reconhece as imagens

Em poucas palavras. Diante das ondas gravitacionais de verdade, a rede "estranha" todas as fotos: elas não se parecem com nada do treino. Então a resposta dela para esses casos não tem valor.

Com a renderização padrão, **os 475 sinais dos 218 eventos ultrapassam o limite de Mahalanobis em todos os cinco modelos** e são rejeitados como fora do domínio. Nenhum fica em "revisar" ou como candidato em domínio. As classes forçadas mostram o que acontece quando se ignora esse alerta: a rede distribui quase todos os sinais entre duas classes genéricas, None_of_the_Above (243) e Extremely_Loud (231), inclusive o GW150914, a primeira onda detectada.

Uma auditoria indica que essas respostas dependem de propriedades globais da imagem, e não do sinal: nove estatísticas simples de brilho preveem se a rede dirá None_of_the_Above com acurácia balanceada de 0,769 (AUROC 0,817). É o comportamento de um classificador fora do seu domínio, que responde a "atalhos" da imagem.

> **Por que as imagens são tão diferentes?** As imagens de treino vêm de painéis prontos do Gravity Spy, com fundo cinza e uma escala de cores fixa. Os Q-grams dos eventos são produzidos pelo nosso pipeline, com outra escala de intensidade, janelas centradas em fusões de buracos negros e, em muitos casos, sinais fortes. A rede aprendeu a aparência específica das imagens de treino, e qualquer mudança sistemática nessa aparência basta para tirá-la do domínio.

5. Resultado 3 — desenhar na escala do treino aproxima, mas não resolve

Em poucas palavras. Quando desenhamos as fotos dos eventos com as mesmas cores das fotos de treino, a rede passa a achar muitas delas familiares e chama os eventos mais fortes de "Chirp". Mas ela fica insegura, e a maior parte desses casos ainda é rejeitada.

Mesmos 475 sinais, modelos e limites — muda só a renderização	Padrão (percentis)	Escala Gravity Spy
Rejeitados (fora do domínio)	475	253
Em revisão	0	205
Candidatos em domínio	0	17
Acima do limite de Mahalanobis	475	49
Acima do limite de energia	0	228
Confiança média do ensemble	0,735	0,536
Sinais classificados como Chirp	0	58 (em 46 eventos)

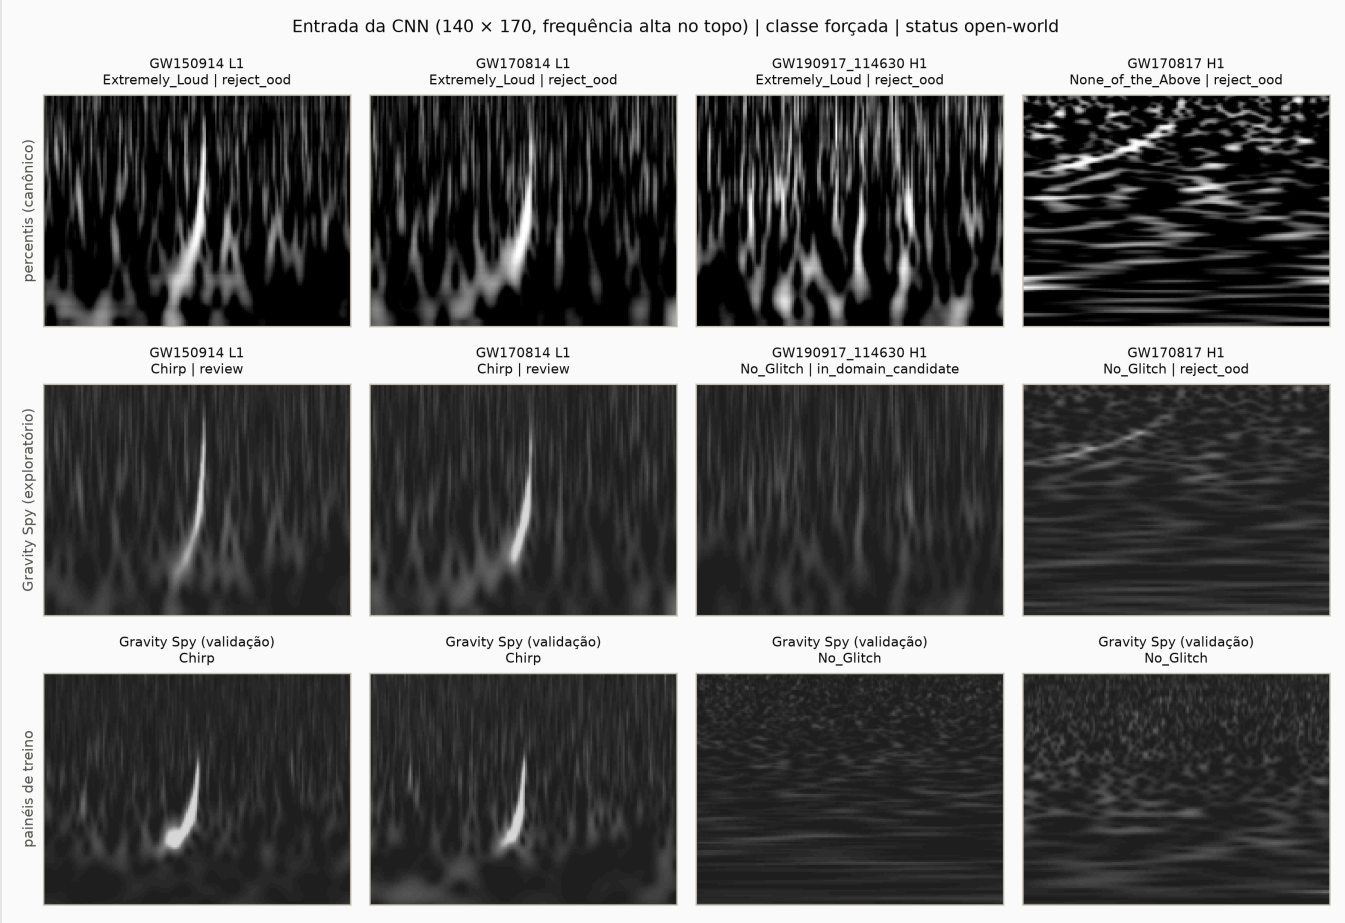


Figura 3 – O que a rede vê. Linha de cima: eventos com a renderização padrão (fundo preto, ruído realçado). Linha do meio: os mesmos eventos na escala Gravity Spy. Linha de baixo: imagens de validação do Gravity Spy, que a rede conhece. A escala Gravity Spy aproxima a aparência das imagens de treino.

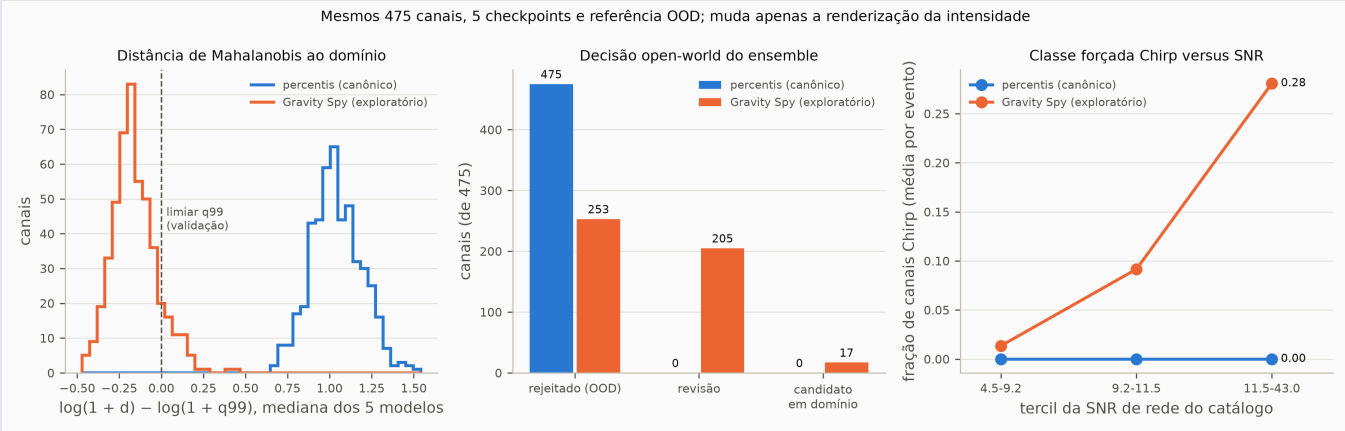


Figura 4 – Efeito da renderização. À esquerda, a distância ao domínio cai para perto do limite. No centro, as decisões. À direita, a fração de sinais chamados de Chirp cresce com a força do evento (SNR de rede), o que só acontece na escala Gravity Spy.

O resultado é promissor, mas incompleto, por três motivos:

- **Os dois medidores discordam.** A distância de Mahalanobis passa a dizer “familiar”, mas o escore de energia, que antes não rejeitava nada, passa a rejeitar 228 sinais, porque a rede fica menos confiante. Enquanto essa discordância não for entendida, não há critério seguro de “em domínio”.
- **Os acertos aparentes não são confiáveis.** Os sinais chamados de Chirp nos eventos mais fortes (GW230814, GW231226, GW230627, GW200129, GW150914) são, na maioria, **rejeitados** como fora do domínio. O GW150914, por exemplo, é Chirp nos dois detectores, mas rejeitado em H1 e só “em revisão” em L1.

- **Os 17 candidatos em domínio são todos No_Glitch** (SNR de rede entre 7,6 e 14,5; 4 deles do Virgo): a rede reconhece como familiar justamente o que se parece com ruído comum, não os sinais.

6. Onde a rede olha — Grad-CAM no GW150914

> **Em poucas palavras.** Na escala Gravity Spy, a rede presta atenção exatamente na curva da onda. É um bom sinal, mas mostrar onde ela olha não prova que a resposta é confiável.

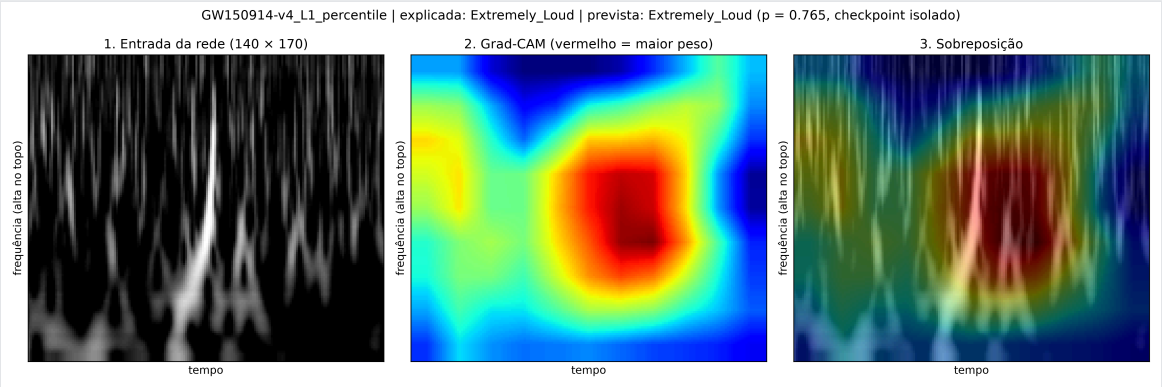


Figura 5 – Renderização padrão: o modelo da seed 42 responde Extremely_Loud.

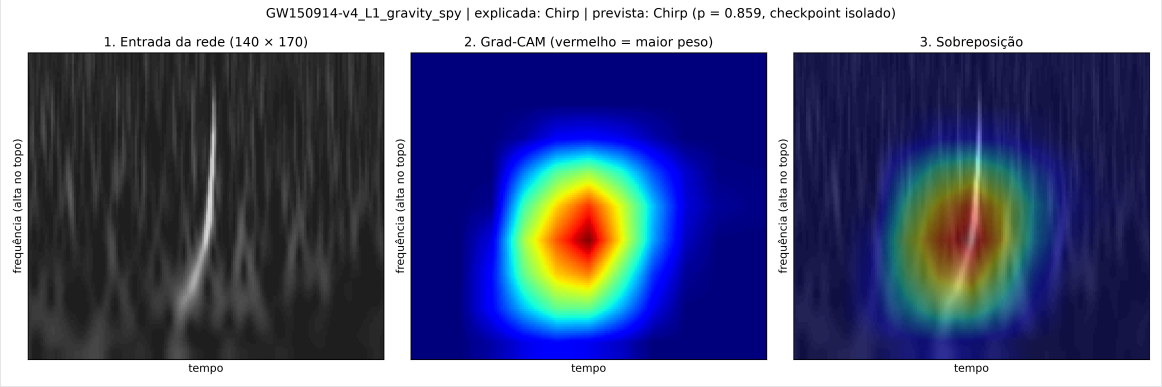


Figura 6 – Escala Gravity Spy: o mesmo modelo responde Chirp (p = 0,86), com a atenção máxima (vermelho) sobre a trilha do sinal.

7. Diagnósticos físicos

Duas análises independentes da rede usam as massas publicadas no catálogo como ponto de partida e servem de checagem do pipeline, não de detecção:

- **Ridge** (estimativa da massa de chirp pela curvatura do sinal na imagem): 201 ajustes aceitos em 475 sinais, com erro relativo mediano de 34,7% em relação ao catálogo.
- **Filtro casado local** (comparação com formas de onda teóricas): 164 eventos analisados; nenhum passa em todos os critérios do diagnóstico completo.

Esses números confirmam que o pipeline recupera parte da física dos eventos, mas não sustentam medição independente de massa, detecção nem taxa de falso alarme.

8. Conclusão

A rede neural melhorou. Com a limpeza dos dados de treino, o treino determinístico e a calibração do teste fora de distribuição, o classificador passou de macro-F1 0,856 para 0,945 nos glitches do Gravity Spy, acerta as 22 classes de forma equilibrada e tem um critério confiável para dizer quando não conhece uma imagem (1% de alarmes falsos em imagens normais).

Mas ainda não consegue identificar os eventos reais. Com a renderização padrão, a rede declara os 475 sinais dos 218 eventos como fora do seu domínio, e suas classes para eles não têm significado. Com a renderização na escala Gravity Spy, ela se aproxima do domínio e chega a apontar Chirp nos eventos mais fortes, mas a maioria desses casos continua rejeitada, os dois medidores de familiaridade discordam e os únicos sinais aceitos como familiares são classificados como ruído comum (No_Glitch). Não há, hoje, nenhuma configuração em que a rede reconheça os eventos reais de forma confiável.

Vale lembrar que a rede foi treinada para classificar a *aparência* de glitches, não para detectar ondas gravitacionais: a classe Chirp do Gravity Spy descreve um formato, não uma origem astrofísica. O resultado negativo é, portanto, uma informação útil: ele mostra que um classificador de glitches não pode ser transferido diretamente para os eventos do catálogo, e indica que a diferença de aparência das imagens (a "mudança de domínio") é o principal obstáculo.

9. Limitações

- A comparação de renderizações é exploratória e não foi preregistrada; nenhum limite foi ajustado depois de ver os resultados, mas os intervalos de confiança não têm correção para múltiplas comparações.
- A população muda entre treino e uso: o treino tem glitches avulsos; o uso, janelas centradas em fusões. Isso dificulta atribuir a mudança de domínio apenas à renderização.
- Os painéis do Gravity Spy cobrem uma faixa de frequência própria, diferente da faixa de 20–512 Hz dos Q-grams do catálogo.
- O Grad-CAM tem baixa resolução (9 × 11 células) e foi examinado apenas em exemplos.

10. Próximos passos

- **Entender a discordância entre os medidores** de Mahalanobis e de energia na escala Gravity Spy.
- **Controles negativos:** aplicar o mesmo pipeline a trechos sem evento, para saber como a rede trata ruído puro do catálogo.
- **Aproximar os domínios no treino:** por exemplo, treinar ou ajustar a rede com Q-grams produzidos pelo nosso próprio pipeline, ou com injeções sintéticas de chirps.
- **Preregistrar** o teste da escala Gravity Spy, se o grupo decidir seguir por ela, com critério de "em domínio" definido antes.
- **Redigir o resultado negativo de validade externa** como primeiro texto científico.

11. Confiabilidade destes resultados

Todos os números deste relatório foram produzidos numa reprodução independente da linha gwproject 2.0 (Relatório V3). A base de treino e o treino das cinco redes saíram idênticos aos do professor, byte a byte, e o catálogo, as decisões fora de distribuição e o experimento de renderização se repetiram com diferença de no máximo um sinal em 475. A conclusão, portanto, não depende de uma máquina ou execução específica.

Documentos relacionados: Relatório V3 (reprodução), Errata do Relatório V2, Glossário (`docs/Glossario.pdf`), `VALIDATION_REPORT.md` e `research/RENDERIZADOR_GRAVITY_SPY.md`. Figuras 1 e 2: `docs/relatorios/fontes/resultados/make_figures.py`; Figuras 3 e 4: `research/figures/renderizador_gravity_spy_figuras.py` sobre as execuções de 17/10/2026; Figuras 5 e 6: `gwproject research gradcam`.