RELATÓRIO DE ACOMPANHAMENTO DE PESQUISA CIENTÍFICA · VERSÃO 2

Classificação de Glitches em Dados do LIGO com CNNs e Análise de Interpretabilidade

Projeto 3 – Ondas Gravitacionais · PIC Astronomia · 07 de outubro de 2026

1. Identificação do Projeto

Título do Projeto	Classificação de Glitches em Dados do LIGO com CNNs e Análise de Interpretabilidade (Projeto 3 – Ondas Gravitacionais)
Grupo de Pesquisa	PIC Astronomia
Período Abrangido	Setembro – Outubro de 2026
Versão / Data	V2 – 07/10/2026 (substitui o relatório de 27/09/2026)
Estágio do Cronograma	Refinamento (M12–M16) – **reaberto** após auditoria do pipeline; a fase de redação (M16–M20) fica condicionada aos itens da seção 10
Alvo de Publicação	Classical and Quantum Gravity (CQG) ou Research Notes of the AAS (RNAAS)

2. Resumo Executivo

O projeto treina uma ResNet-18 no conjunto Gravity Spy (22 classes) e a aplica a eventos reais do catálogo GWTC. Esta versão registra uma **auditoria completa do código e dos resultados** do relatório V1, que encontrou três defeitos de pipeline com impacto direto nas conclusões:

1. **Q-grams do GWTC transpostos.** O gwpy salva o Q-transform como (tempo × frequência), mas o pipeline o tratava como (frequência × tempo). O "recorte de 1 s" cortava uma faixa de frequência e o "flip de frequência" invertia o tempo.
2. **Cores do Grad-CAM trocadas.** O OpenCV gera o mapa de calor em BGR e o matplotlib o exibia como RGB: vermelho (atenção máxima) aparecia como azul. A hipótese da "Detecção por Silhueta" do V1 decorria desse erro.
3. **Escala de intensidade incompatível com o treino.** O estiramento por percentis deixava os Q-grams reais com fundo preto e ruído muito contrastado, enquanto as imagens de treino têm fundo cinza (escala viridis 0–25,5).

Com os três defeitos corrigidos, o comportamento da rede muda qualitativamente: o Grad-CAM mostra que **a rede olha diretamente para o glitch ou o sinal**, e nos dados reais ela passa de 2 para 15 classes previstas, reconhecendo como *Chirp*, com confiança acima de 95%, os eventos mais intensos do catálogo (GW150914, GW170814, GW190521_074359, GW190630 etc.). Por outro lado, os resultados de dados reais do V1 (38 discordâncias "Extremely_Loud × None_of_the_Above" e o estudo de caso GW151012) **não se sustentam**, e todos os 150 canais ainda ficam acima do limiar de detecção fora de distribuição (OOD). O projeto não está pronto para a redação; está numa posição metodologicamente muito mais sólida para chegar lá.

Além disso, o filtro casado do kit didático (`gw_student_kit`) foi corrigido (PR #1, Daniel Tedesco): ele produzia SNRs da ordem de 10^{11} e agora dá $\rho \approx 10{,}8$ para o GW150914 no detector L1, no instante correto da fusão (seção 6.5).

3. Contexto e Objetivo da Pesquisa

Problema investigado

Os interferômetros LIGO Hanford (H1) e Livingston (L1) são afetados por transientes instrumentais (*glitches*) que podem mascarar ou imitar sinais de ondas gravitacionais. A classificação automática desses transientes é parte da caracterização de qualidade dos dados.

Objetivos

- **Arquitetura:** adaptar e treinar uma ResNet-18 para espectrogramas em tons de cinza (22 classes Gravity Spy).
- **Interpretabilidade:** usar Grad-CAM para verificar se a rede se apoia na morfologia do transiente ou em atalhos (bordas, fundo).
- **Dados reais (GWTC):** aplicar o classificador a Q-grams de eventos do catálogo, medir a compatibilidade com o domínio de treino (OOD) e estudar as discordâncias entre detectores.

Hipóteses reformuladas (testáveis)

- **H1 – Atenção:** nas classes de treino, a região de maior atenção do Grad-CAM se sobrepõe à região do transiente mais do que regiões aleatórias de mesma área (a medir por oclusão/deleção).
- **H2 – Domínio:** com o pré-processamento harmonizado, a fração de canais GWTC dentro do limiar OOD q99 é maior que zero e cresce com a SNR do evento.
- **H3 – Controle positivo:** eventos de SNR alta são classificados como *Chirp* nos detectores LIGO com maior frequência do que eventos de SNR baixa.

4. Histórico e Evolução do Trabalho

Etapa	Objetivo	Procedimento / Resultado	Decisão
1. Ambiente	Estabilizar o pipeline	NumPy 1.26.4 / SciPy 1.11.4, PyTorch 2.5.1 + CUDA 12.1, OpenCV < 4.10, ambiente conda `gw`.	Concluído
2. Treino multiseed	Robustez estocástica	5 seeds (11, 23, 42, 71, 101); macro-F1 0,856 ± 0,006 (seção 6.1).	Modelo estabelecido
3. Discordâncias (V1)	Aplicar ao GWTC	38 eventos com discordância entre detectores; só 2 classes previstas.	Invalidado (defeitos 1 e 3)
4. Grad-CAM (V1)	Interpretabilidade	`run_gradcam.py` com hook em `layer4[-1].conv2`.	Corrigido (defeito 2)
5. "Silhueta" (V1)	Testar viés de borda	Interpretação baseada em cores invertidas.	Descartado
6. GW151012 (V1)	Estudo de caso	Conversão ad hoc `.npy → .png` com pré-processamento diferente do oficial e eixos trocados.	Invalidado
7. Auditoria	Conferir V1 contra o repositório	Revisão de código, saídas e contas; identificação dos defeitos 1–3.	Concluído
8. Correção da orientação	Eixos corretos	Parâmetro `layout="gwpy"`; testes com GW150914 (pico em t ≈ +0,016 s, ≈ 160 Hz).	Concluído
9. Correção de cores	Grad-CAM legível	Conversão BGR → RGB; figuras refeitas.	Concluído

10. Escala Gravity Spy	Reduzir a diferença de domínio	`render_mode="gravity_spy"` como padrão; ensemble reprocessado.	Concluído
11. Kit didático	Filtro casado com SNR correta	Normalização FINDCHIRP, template newtoniano, injeção pela SNR ótima (PR #1, Daniel Tedesco); 6 testes novos.	Concluído

5. Metodologia

Equipamento e software

AMD Ryzen 5 5600G, 32 GB RAM, NVIDIA GeForce RTX 3060 (12 GB). Windows 11, ambiente conda `gw` (Python 3.12, PyTorch 2.5.1 + CUDA 12.1, torchvision 0.20.1, gwpy 3.0.14, NumPy 1.26.4, SciPy 1.11.4). O pacote ativo é `src/gwproject` (instalação editável).

Dados

- **Treino:** Gravity Spy v1.1, conjunto harmonizado `trainingset_harmonized_20_512` (banda 20–512 Hz, janela de 1 s), divisões oficiais: 5586 treino / 1200 validação / 1179 teste.
- **Dados reais:** 61 eventos GWTC com dados disponíveis, 150 canais (H1 = 53, L1 = 54, V1 = 43). Q-transform do gwpy: `qrange = (4, 64)`, 20–512 Hz, janela de 4 s, branqueado, normalização pela mediana.

Modelo

ResNet-18 pré-treinada no ImageNet, com `conv1` adaptada para um canal (stride 2) e **sem maxpool**; cabeça linear de 22 classes; AMP; perfil `cuda_balanced` (batch 32). Entrada 140 × 170 px em cinza, normalizada com `Normalize([0.5],[0.5])` para [−1, 1].

Pré-processamento dos Q-grams reais (corrigido)

1. Transposição (tempo × frequência → frequência × tempo) e recorte central de 1 s.
2. Inversão do eixo de frequência (altas frequências no topo, como no Gravity Spy).
3. Energia normalizada recortada em [0; 25,5] e mapeada no colormap viridis, convertida para cinza (ITU-R 601), exatamente como as imagens de treino são lidas.
4. Redimensionamento para 140 × 170 e normalização para [−1, 1].

Grad-CAM

Hooks em `layer4[-1].conv2`. Os pesos de cada filtro são a média espacial dos gradientes, $\alpha_k^c = (1/Z)\ \Sigma_{ij}\ \partial y^c / \partial A^k_{ij}$; o mapa é $M^c = \mathrm{ReLU}(\Sigma_k\ \alpha_k^c\ A^k)$. O ReLU atua sobre a **soma ponderada**, não sobre os gradientes. Como o modelo não tem maxpool, a redução espacial é de 16× e o mapa tem **9 × 11 células** (140×170 → 70×85 → 35×43 → 18×22 → 9×11), interpoladas para o tamanho da imagem. Cores: escala JET convertida para RGB (**vermelho = atenção máxima**), sobreposição 60% imagem / 40% mapa.

Ensemble e detecção OOD

Média das probabilidades dos 5 seeds; fração de votos do modelo vencedor; entropia e informação mútua. OOD por distância de Mahalanobis no espaço de 512 dimensões (referência construída com 1200 imagens de validação, seed 42; limiares q95 = 563 e q99 = 638) e por energia livre.

6. Experimentos, Testes e Análises

6.1 Desempenho no conjunto de teste Gravity Spy

Métrica (teste, 1179 amostras)	Média	Desvio	Mín.	Máx.
Macro-F1	0,856	0,006	0,846	0,863
Acurácia balanceada	0,844	0,010	0,831	0,856
Acurácia	0,909	0,004	0,904	0,914
Kappa de Cohen	0,900	0,004	0,894	0,905

As classes mais difíceis são **No_Glitch** (F1 0,47–0,56), **1400Ripples** (0,50–0,64) e **Paired_Doves** (0,57–0,67). *Chirp* tem F1 = 1,00 em todos os seeds. No seed 42 (usado no Grad-CAM), a menor F1 é No_Glitch (0,526), e não 1400Ripples (0,600) como afirmava o V1. A matriz de confusão do seed 42 está na Figura 1; as dos demais seeds estão no Anexo C.

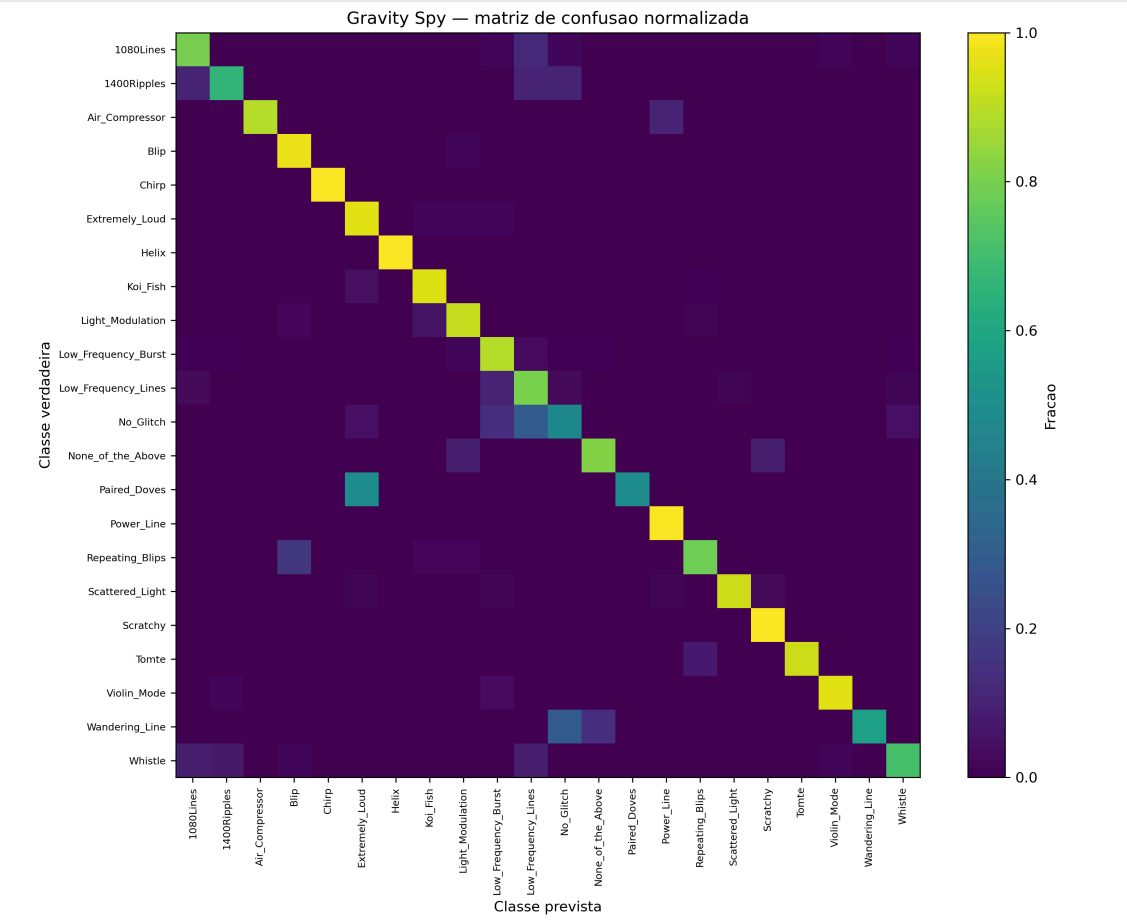


Figura 1 – Matriz de confusão normalizada no conjunto de teste (seed 42). Cada linha soma 1 (fração da classe verdadeira). As maiores confusões são Paired_Doves → Extremely_Loud (2 de 4 amostras), No_Glitch → Low_Frequency_Lines (6 de 21) e Wandering_Line → No_Glitch (2 de 7) – classes com poucas amostras de teste, o que torna essas frações instáveis; Chirp, Helix, Power_Line e Scratchy ficam praticamente na diagonal.

6.2 Grad-CAM nas classes de treino (cores corrigidas)

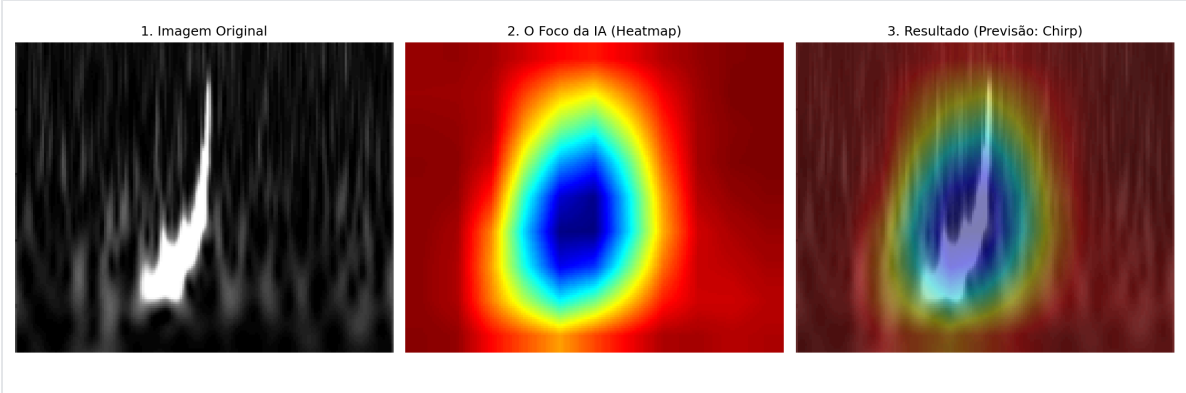


Figura 2 – Figura do V1 (cores trocadas). O azul sobre a onda era, na verdade, a região de atenção máxima. A leitura "a rede foca no fundo vazio" e o cálculo (−5)·(−1) = +5 do V1 decorrem desse erro.

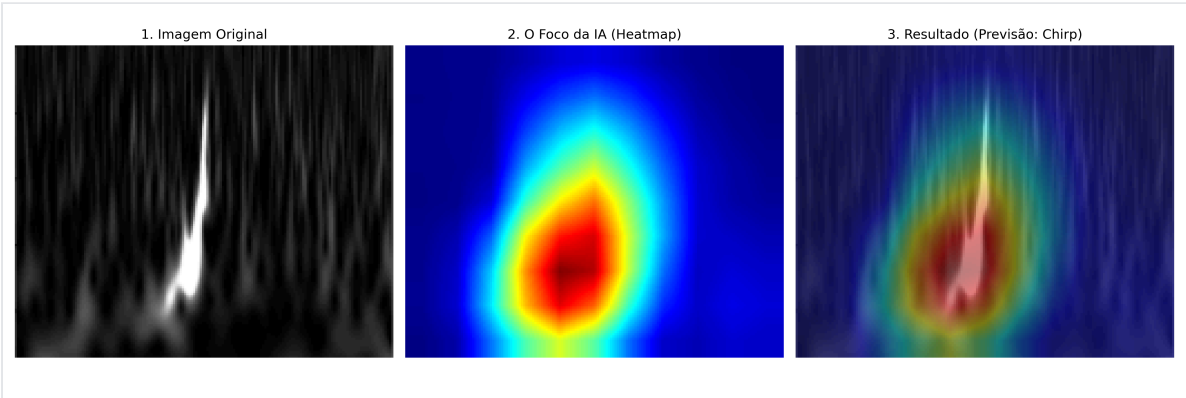


Figura 3 – Chirp (treino), cores corretas. A atenção máxima (vermelho) está sobre o próprio chirp, na parte de menor frequência e maior energia da trilha.

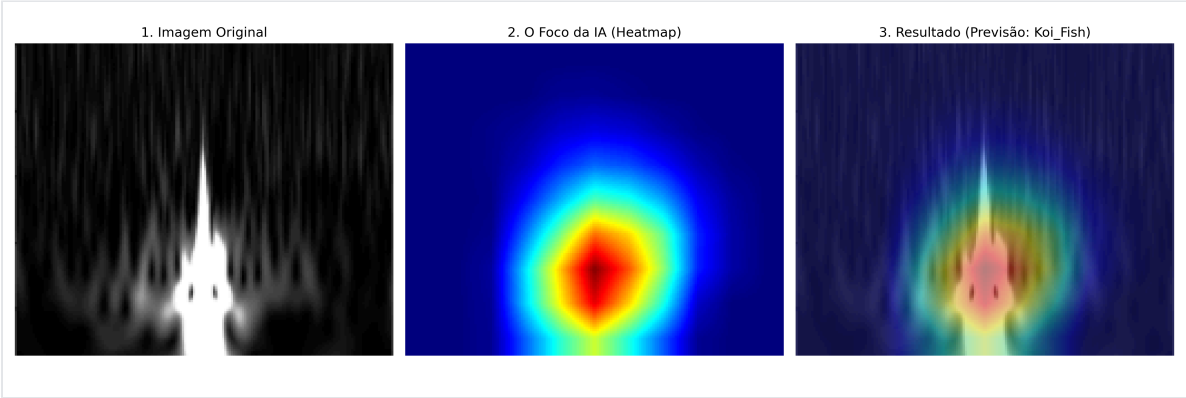


Figura 4 – Koi_Fish (treino). A atenção se concentra no "corpo" do glitch de banda larga.

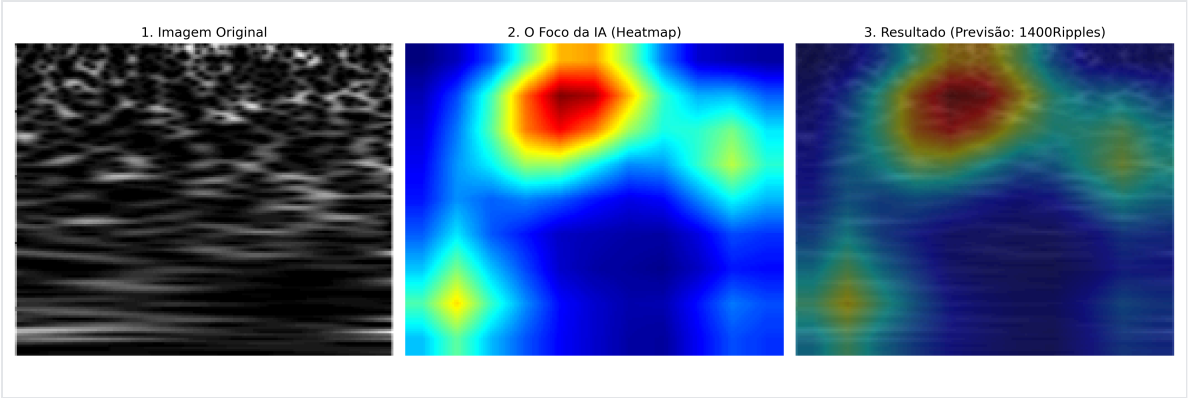


Figura 5 – 1400Ripples (treino). A atenção se concentra na textura de alta frequência do topo, com um foco secundário no canto inferior esquerdo.

> **Interpretação.** Nos três exemplos, a rede se apoia na região do transiente, e não no fundo. Isso é **compatível** com aprendizado morfológico, mas três exemplos escolhidos não constituem prova de ausência de viés: o mapa tem resolução de 9 × 11 células e as amostras não são as mesmas do V1 (os identificadores originais não foram registrados). Testes quantitativos estão na seção 10.

6.3 Aplicação aos eventos GWTC (ensemble de 5 modelos)

Indicador (150 canais, 61 eventos)	V1 (transposto)	Transposição corrigida	Escala Gravity Spy
Classes distintas previstas	2	2	15
Canais classificados como Chirp	0	0	34
Eventos com discordância entre detectores (inclui V1)	38	38	50
Eventos com discordância H1 × L1	21 / 47	19 / 47	32 / 47
Mediana da distância de Mahalanobis	18 424	11 670	2 228
Canais acima do limiar OOD q99 (638)	150	150	150

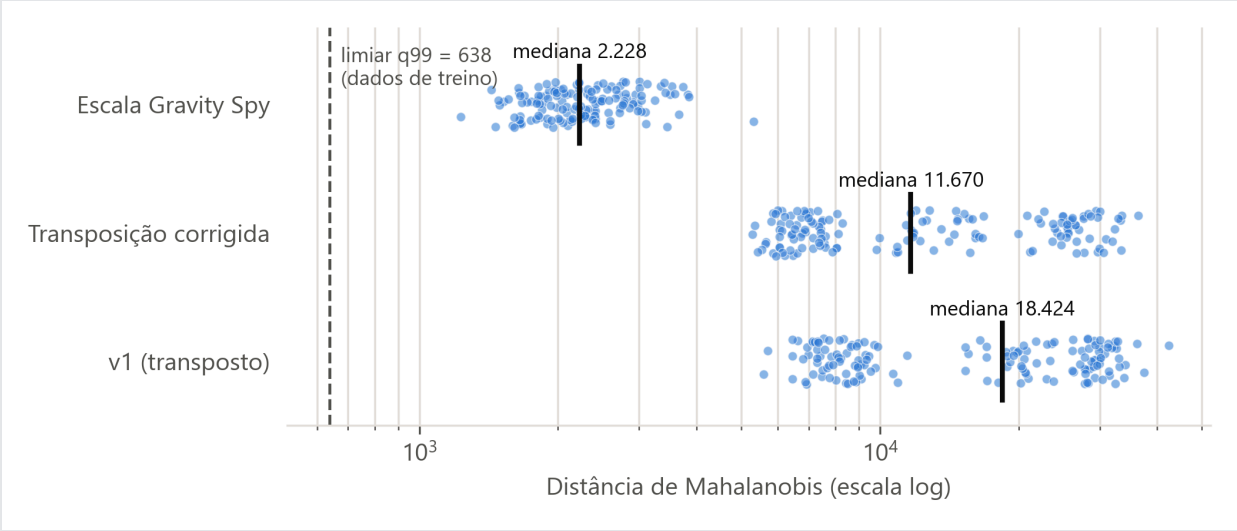


Figura 6 – Distância de Mahalanobis por canal nas três renderizações. Cada ponto é um canal; o traço preto é a mediana. A correção aproxima os dados reais do domínio de treino em cerca de 8×, mas todos os canais permanecem à direita do limiar q99.

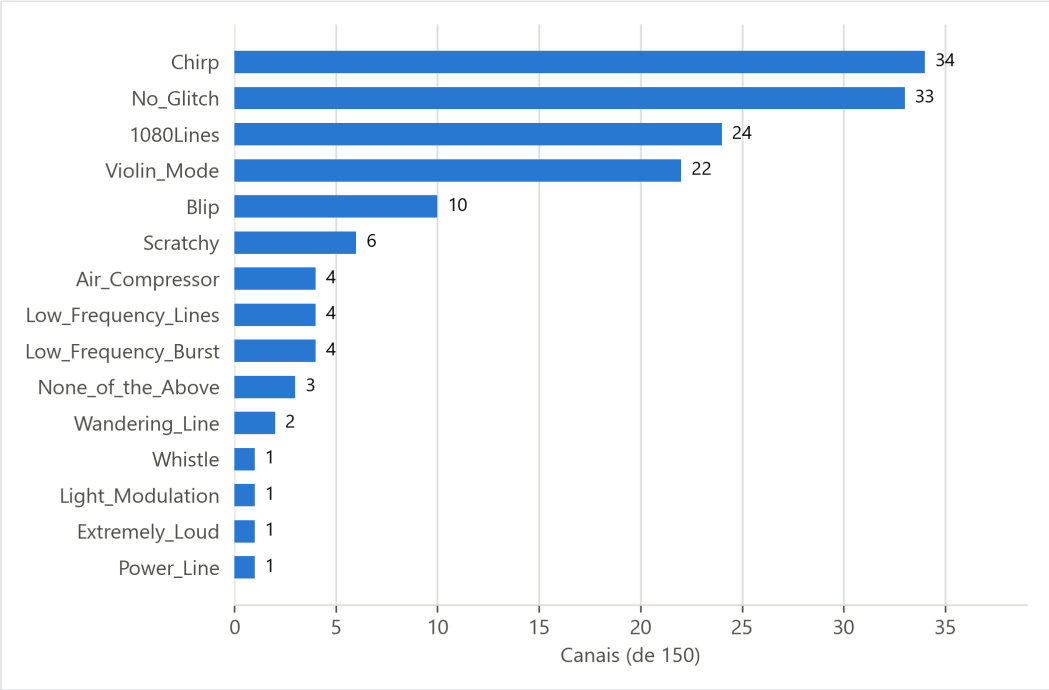


Figura 7 – Classes previstas pelo ensemble com a escala Gravity Spy. Nenhum canal do Virgo (V1) é classificado como Chirp, o que é consistente com a menor sensibilidade desse detector nos eventos analisados.

Controle positivo. Os 11 canais classificados como Chirp com confiança ≥ 0,95 (todos com 5/5 votos) pertencem a eventos reconhecidamente intensos:

Evento	Detector	Confiança	Evento	Detector	Confiança
GW190521_074359	L1	0,9999	GW190910_112807	L1	0,997
GW170814	L1	0,9990	GW190828_063405	L1	0,995
GW190630_185205	L1	0,9988	GW200311_115853	H1	0,986
GW150914	L1	0,9987	GW170809	L1	0,985
GW190828_063405	H1	0,9977	GW190519_153544	L1	0,981
GW190727_060333	H1	0,960			

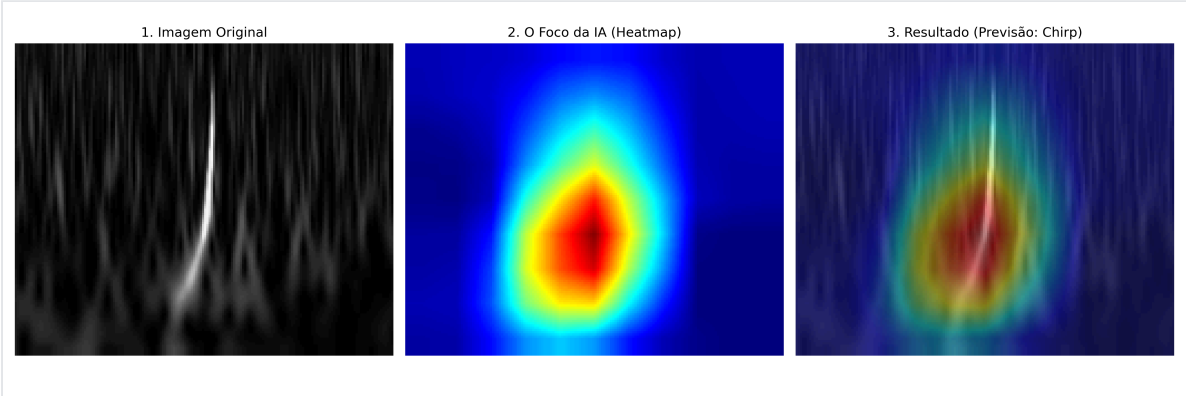


Figura 8 – GW150914, L1, renderização Gravity Spy (seed 42): Chirp. A atenção máxima coincide com a trilha do sinal astrofísico.

> **Cautela.** A classe *Chirp* do Gravity Spy descreve morfologia, não origem astrofísica, e a softmax não é probabilidade física. Como todos os canais continuam acima do limiar OOD, os resultados em dados reais são **exploratórios**. A concordância com os eventos mais intensos é um indício favorável, não uma validação.

6.4 Estudo de caso GW151012 (revisado)

Fonte	H1	L1
Relatório V1 (conversão ad hoc, eixos trocados)	Extremely_Loud	None_of_the_Above
Ensemble V1 (pipeline oficial, transposto)	None_of_the_Above (0,81)	Extremely_Loud (0,52)
Ensemble, transposição corrigida	None_of_the_Above (0,72)	None_of_the_Above (0,50; 2/5 votos)
Ensemble, escala Gravity Spy	Violin_Mode (0,64)	Scratchy (0,76)
Seed 42 isolado, escala Gravity Spy	1080Lines	Scratchy

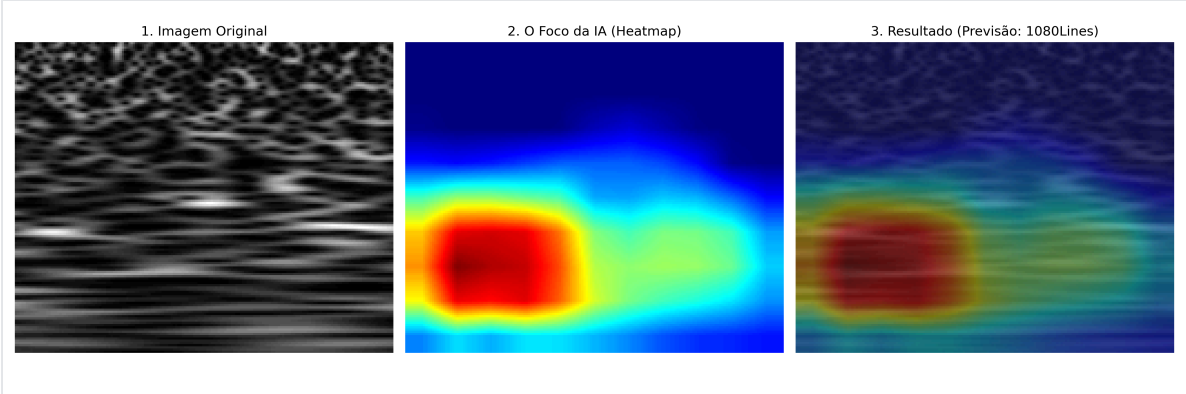


Figura 9 – GW151012, H1 (seed 42): 1080Lines. Imagem dominada por ruído de fundo; a atenção fica em uma região de baixa frequência, sem transiente evidente.

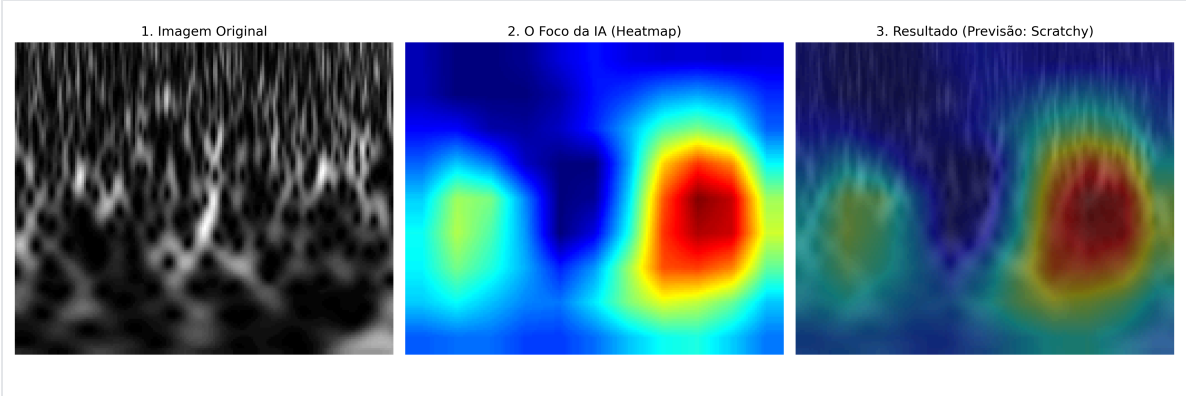


Figura 10 – GW151012, L1 (seed 42): Scratchy.

O GW151012 é um evento de baixa significância. O filtro casado do próprio projeto obtém **SNR de rede de 5,5** e reprova nos critérios de detecção (o valor publicado é ≈ 10). Nenhuma das versões mostra um glitch claro em H1 com L1 "limpo", e a classificação muda conforme a renderização e o seed. **A conclusão do V1 – "a IA isolou cirurgicamente um defeito no H1 e atestou a limpeza do L1" – não se sustenta.** Também não há registro conhecido de glitch que tenha "sufocado" o sinal em H1, e o atraso máximo entre H1 e L1 é de ~10 ms, não "no milissegundo seguinte, em continente distinto".

6.5 Kit didático: correção do filtro casado

O `gw_student_kit` é um kit independente do pacote `gwproject`, usado para ensinar filtragem, espectrogramas e filtro casado. A versão anterior produzia SNRs sem sentido físico: ~1,6 × 10^9 na demonstração sintética e ~1,1 × 10^{11} no GW150914, com o pico fora do instante do evento. A correção, de autoria de **Daniel Tedesco** (PR #1, mesclado em 10/10/2026), atacou quatro causas:

1. **Normalização da transformada de Fourier:** faltavam os fatores Δt da DFT, o que inflava a SNR por um fator da ordem da taxa de amostragem. O cálculo passou a seguir as convenções de Allen et al. (2012, FINDCHIRP): $\sigma^2 = 4\Delta f \, \Sigma|\tilde{h}|^2/S$ e $\rho = |z|/\sigma$.
2. **Divisão por PSD quase nula:** fora de 30–400 Hz a PSD dos dados filtrados é praticamente zero e o template não era filtrado. Agora o template recebe o mesmo passa-banda, e a soma fica restrita à banda.
3. **Instante do pico:** o índice do máximo da correlação é um atraso em relação ao início do template, não o instante de fusão. A nova função `align_to_merger` faz a conversão.
4. **Injeção sintética:** a "SNR" era uma razão entre valores RMS; com 16 mil amostras, "SNR = 14" equivalia a ρ ≈ 1.800. A injeção agora usa a SNR ótima do filtro casado, $\rho = \sqrt{\Sigma h^2}/\sigma$.

O template passou a ser um chirp de ordem dominante ("newtoniano") calculado a partir da massa de chirp no referencial do detector, e o kit ganhou leitura dos arquivos HDF5 oficiais do GWOSC e semente fixa para o ruído sintético.

Verificação (reproduzida localmente)	Resultado
$\langle\rho^2\rangle$ em ruído gaussiano (valor teórico 2)	≈ 2 (teste automatizado)
Demonstração sintética, ρ ótima injetada = 14, semente 2026	ρ = 12,91 no instante da injeção (3,000 s); parte do chirp fica fora de 30–400 Hz
GW150914, L1, $\mathcal{M}$ = 30,69 $M_\odot$ (detector)	ρ = 10,80, fusão em +16,021 s
GW151012, L1, $\mathcal{M}$ = 18,72 $M_\odot$	ρ = 5,29, fusão em +16,046 s
GW151012, H1	pico global ρ = 5,04 em +1,8 s, no ruído (sem detecção)
Suíte de testes do projeto	66 testes passando (6 novos para o kit)

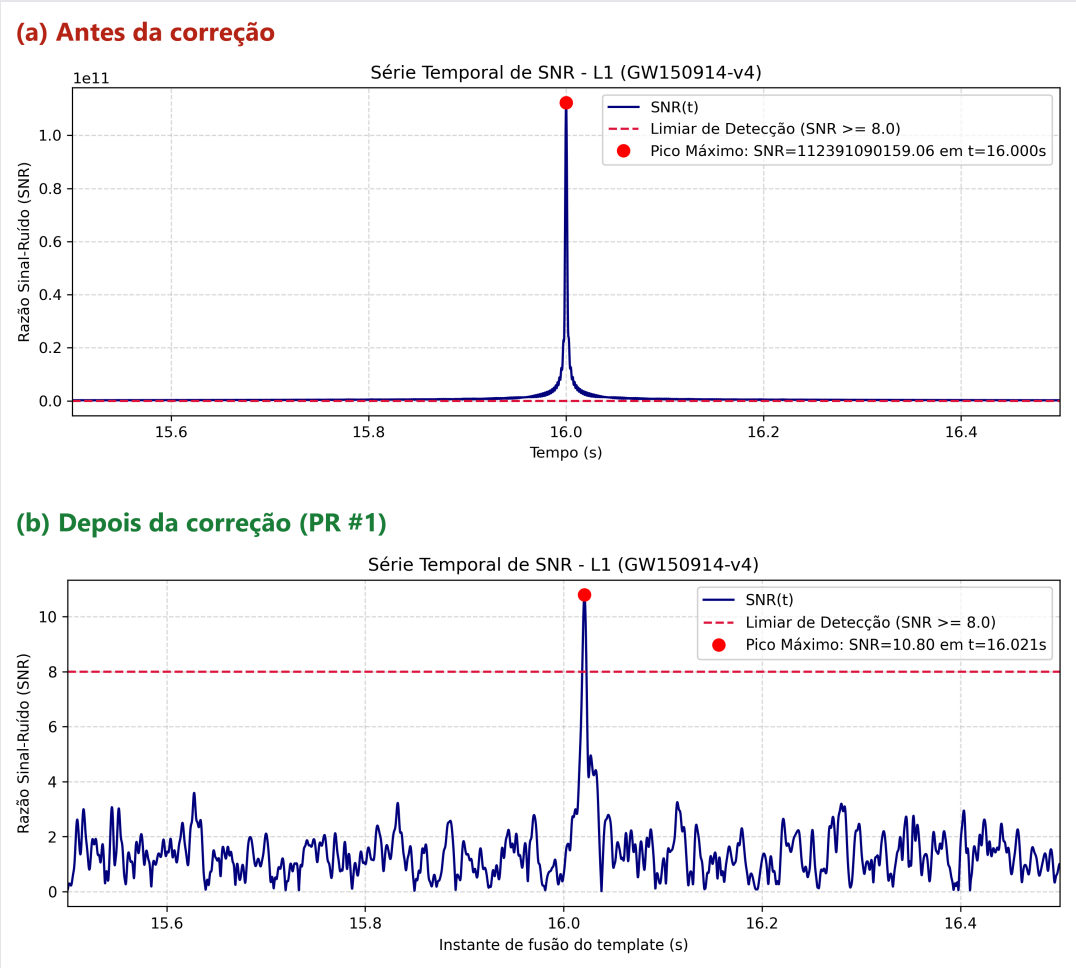


Figura 11 – Série de SNR do filtro casado do kit para o GW150914 (L1). (a) Antes da correção, o pico chegava a ~1,1 × 10^{11}. (b) Depois da correção, ρ = 10,8 destaca-se claramente do ruído (ρ ≈ 1–3), com o eixo indexado pelo instante de fusão do template.

> **Limites.** O template não tem correções pós-newtonianas, spins, fusão nem ringdown, e a PSD é estimada nos mesmos dados. Por isso a SNR do kit é indicativa e menor que a publicada pela colaboração; não há banco de templates, teste χ^2 nem taxa de falso alarme. O kit tem fim didático e não substitui o filtro casado do `gwproject` (seção 8).

7. Decisões Metodológicas Consolidadas

Decisão	Justificativa	Estado
Layout `gwpy` (transpor Q-grams)	O gwpy grava (tempo, frequência); verificado com o pico do GW150914. Protegido por teste automatizado.	Em uso
Renderização "gravity_spy" como padrão	Reproduz a escala das imagens de treino; reduz a distância OOD em ~8× e recupera o controle positivo. A renderização por percentis continua disponível (`render_mode = "percentile"`).	Em uso
Grad-CAM em RGB	Corrige a troca de cores; vermelho = atenção máxima.	Em uso
Normalização [−1, 1]	Mantida, igual ao treino. A interpretação "molde de contraste" associada a ela no V1 foi descartada.	Em uso
Ensemble de 5 seeds + OOD	Reduz a dependência de um único modelo (o GW151012 mostra divergência entre seed 42 e ensemble).	Em uso

Kit didático com normalização FINDCHIRP	SNR fisicamente interpretável ($\rho^2 \sim \chi^2_2$ em ruído); comportamento protegido por 6 testes.	Em uso
Figuras V1 arquivadas	Mantidas em `outputs/research/gradcam_legacy_bgr/` para rastreabilidade.	Concluído

8. Problemas, Dificuldades e Limitações

- **Diferença de domínio persistente:** mesmo com a escala correta, 150/150 canais estão acima do limiar q99. Causas candidatas: suavização/interpolação dos PNGs do Gravity Spy, diferenças de janela de branqueamento, e a própria sensibilidade da distância de Mahalanobis em 512 dimensões com 1200 amostras de referência.
- **Referência OOD de um só modelo:** construída com o seed 42 e reutilizada para o ensemble.
- **Grad-CAM de baixa resolução** (9 × 11) e avaliado apenas qualitativamente.
- **Amostras de treino do V1 não registradas:** as figuras de treino foram refeitas com outras amostras.
- **Kit didático:** template de ordem dominante e PSD estimada nos próprios dados; a SNR é indicativa e não estabelece detecção.
- **Filtro casado:** o SNR do GW151012 (5,5) não reproduz o valor publicado (≈ 10), o que precisa ser investigado antes de usar SNR como covariável.

9. Estado Atual da Pesquisa

Item	Status	Observações
Configuração e banco de dados (M4)	Concluído	Gravity Spy harmonizado; 61 eventos GWTC, 150 canais.
Treino da rede (M12)	Concluído	5 seeds, macro-F1 0,856 ± 0,006. Não precisa ser refeito.
Pipeline de Q-grams reais	Corrigido	Orientação e escala corrigidas; 66 testes automatizados passando.
Kit didático (`gw_student_kit`)	Corrigido	Filtro casado com SNR correta (PR #1); figuras refeitas.
Interpretabilidade / viés (M16)	Em andamento	Qualitativo coerente; faltam testes quantitativos.
Análise GWTC / OOD	Em andamento	Controle positivo recuperado; diferença de domínio ainda aberta.
Estudo de caso GW151012	Revogado	Conclusão do V1 não se sustenta.
Redação (M20)	Pendente	Condicionada aos itens de curto prazo da seção 10.

10. Próximos Passos

Curto prazo

- **Fechar a diferença de domínio:** comparar estatisticamente imagens de treino e Q-grams reais (histograma, espectro espacial, suavidade); testar interpolação equivalente à do Gravity Spy; reconstruir a referência OOD por seed.
- **Controles negativos:** processar trechos sem evento (off-source) com o mesmo pipeline e medir a taxa de cada classe.
- **Controles positivos com glitch documentado:** GW170817 (L1) e GW200129 (L1), conferidos no GWOSC.

- **Testar H3:** correlacionar a probabilidade de Chirp com a SNR de rede publicada.

Médio prazo

- **Grad-CAM quantitativo:** teste de sanidade com pesos aleatórios (Adebayo et al.), oclusão/deleção, comparação com `layer3` e Grad-CAM++, e injeção de seno-gaussianas em (t, f) conhecidos.
- **Filtro casado:** PSD de Welch com produto interno ponderado por $1/S_n(f)$, maximizando em tempo e fase, até reproduzir o SNR publicado.

Longo prazo

- Escrita do artigo, com título condizente com os resultados, por exemplo: "Transferência de um classificador Gravity Spy para eventos GWTC: harmonização de domínio, controle positivo e interpretabilidade".

11. Pendências para a Reunião do Grupo

- [ ] Validar com o orientador a revogação das conclusões do V1 (silhueta, 38 discordâncias, GW151012).
- [ ] Aprovar a renderização Gravity Spy como pipeline padrão.
- [ ] Definir o critério de "dentro do domínio" (q95, q99 ou limiar calibrado por controles negativos).
- [ ] Decidir se a análise das 37 "discordâncias restantes" do V1 deve ser substituída pela análise de controles positivos/negativos.

12. Conclusão

A auditoria encontrou três defeitos que, somados, produziram as principais conclusões do relatório V1: a "Detecção por Silhueta" era um artefato de cores trocadas, e o padrão "Extremely_Loud × None_of_the_Above" nos dados reais era consequência de imagens transpostas e de uma escala de intensidade diferente da do treino. Corrigidos esses pontos, o quadro é mais modesto e mais confiável: a ResNet-18 treinada tem bom desempenho no Gravity Spy (macro-F1 0,86), concentra a atenção no próprio transiente e, aplicada aos dados reais com a renderização correta, reconhece os sinais mais intensos do catálogo como *Chirp*. A transferência para dados reais ainda não está validada, porque todos os canais continuam fora do domínio pelo critério de Mahalanobis. Fechar essa lacuna e executar os controles positivos e negativos são as condições para iniciar a redação científica.

Anexo A – Errata do Relatório V1

Afirmação no V1	Correção
"A rede foca no espaço vazio; detecção por silhueta / molde vazado"	Artefato de cores BGR/RGB; a atenção máxima está sobre o transiente.
"O cálculo (−5 × −1,0) gera ativação máxima … não há viés"	Exemplo de uma única camada, sem relação com o mapa da layer4; argumento descartado.
"ReLU forçando derivadas negativas a zero"	O ReLU atua sobre $\Sigma\alpha_k A^k$.
Sobreposição com 50% de transparência	60% imagem / 40% mapa.
1400Ripples é a classe de menor F1	Verdadeiro em 2 de 5 seeds; no seed 42 é No_Glitch.
38 eventos com discordância H1 × L1	38 de 61 eventos com discordância entre quaisquer detectores (inclui Virgo); H1 × L1: 21 de 47.
"100% das falhas opõem Extremely_Loud e None_of_the_Above"	Trivial: só essas duas classes eram previstas, por causa dos defeitos de pré-processamento.
GW151012: H1 Extremely_Loud, L1 None_of_the_Above	O ensemble oficial dava o inverso; com o pipeline corrigido: H1 Violin_Mode, L1 Scratchy.
None_of_the_Above = "ambiente limpo"	A classe limpa é No_Glitch; None_of_the_Above é um glitch fora das demais classes.
"No milissegundo seguinte, em continente distinto"	H1 e L1 observam a mesma janela, com atraso máximo de ~10 ms.
Chirp = "física real"	Classe morfológica do Gravity Spy, não garantia de origem astrofísica.

Anexo B – Reprodutibilidade

Artefato	Local
Correções de código	`src/gwproject/qgram_inference.py` (`layout`, `render_mode`), `scripts/run_gradcam.py`, `scripts/temp_npy_to_png.py`, `scripts/classify_catalog_qgrams*.py`
Configuração	`configs/research_program.toml` e `configs/catalog_analysis.toml` (`flip_frequency = true`, `render_mode = "gravity_spy"`)
Testes	`tests/test_qgram_orientation.py`, `tests/test_student_kit.py` (suíte completa: 66 testes passando)
Ensembles	`outputs/research/gravity_spy_ensemble` (V1), `…_fixed`, `…_gsrender` (atual)
Grad-CAM	`docs/figuras/gradcam_*.png`, `outputs/research/gradcam_fixed/`, `outputs/research/gradcam_legacy_bgr/`
Kit didático	`gw_student_kit/matched_filter.py`, `synthetic.py`, `main_demo.py`; figuras em `gw_student_kit/results/`
Figuras deste relatório	`outputs/research/report_v2/`

Amostras de treino usadas nas Figuras 3–5: Chirp/H1_0fp5wZUWD7, Koi_Fish/H1_08APXWraeY, 1400Ripples/L1_1IjZNes7gG (conjunto harmonizado). Ensemble: seeds 101, 11, 23, 42, 71; referência OOD `outputs/research/ood_reference_seed42.npz`.

Anexo C – Matrizes de Confusão das Demais Seeds

Matrizes normalizadas por linha no conjunto de teste, na mesma escala da Figura 1 (seed 42: macro-F1 0,857 · acurácia 0,908). O padrão de erros se repete entre as seeds: No_Glitch (recall 0,38–0,52), Paired_Doves (0,50) e Wandering_Line (0,57–0,71) estão entre as quatro classes de menor recall em todas elas, completadas por 1400Ripples (seeds 23, 42 e 71) ou Whistle (seeds 11 e 101). Chirp tem recall 1,00 em todas. Arquivos: `outputs/gravity_spy_harmonized/seed_*/confusion_matrix.png` (regeneráveis com `python -m scripts.replot_confusion_matrices`).

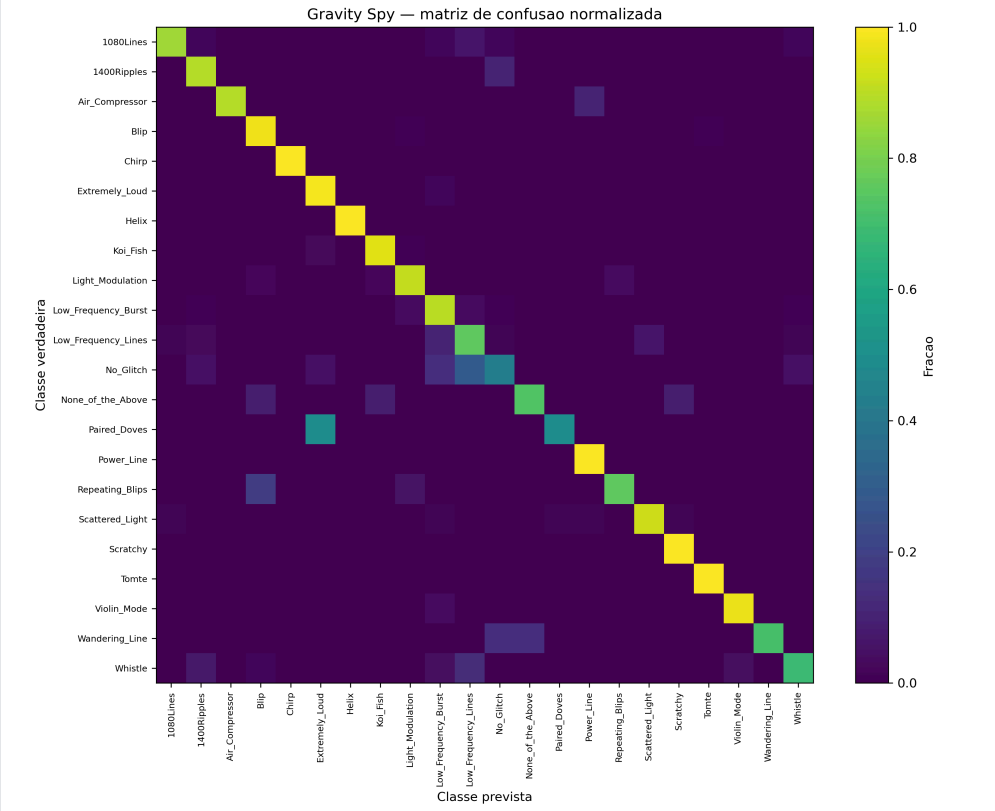


Figura C1 – Seed 11. Macro-F1 0,863 · acurácia 0,914 (teste, 1179 amostras).

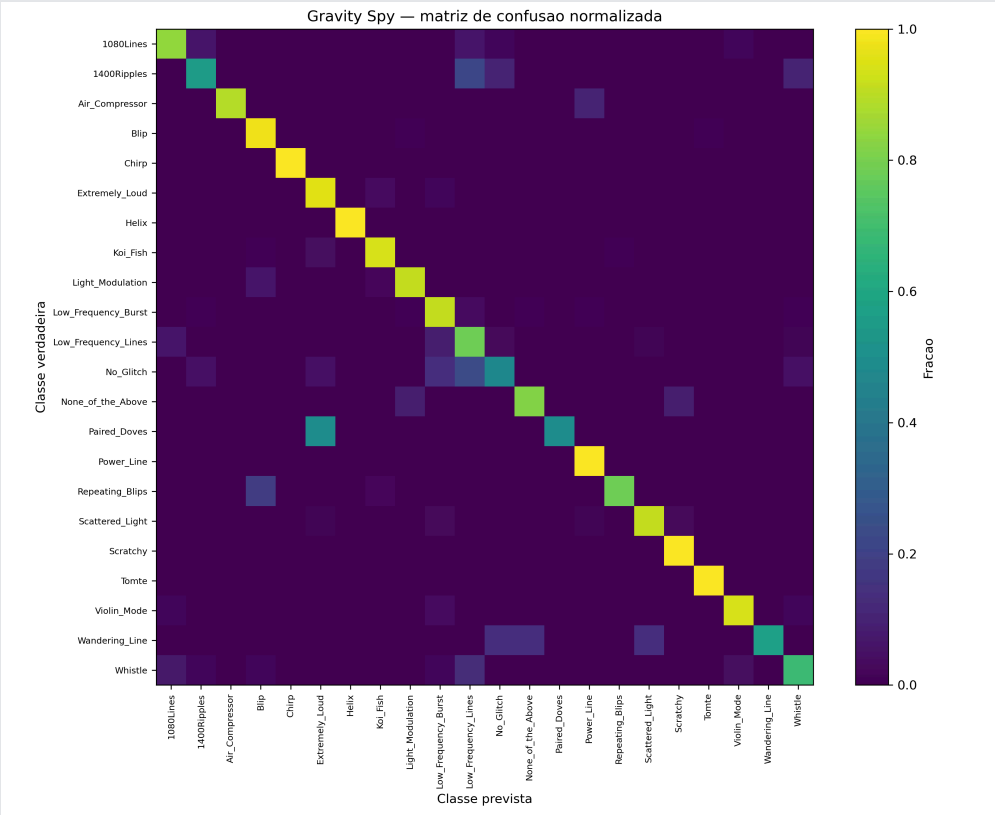


Figura C2 – Seed 23. Macro-F1 0,855 · acurácia 0,909 (teste, 1179 amostras).

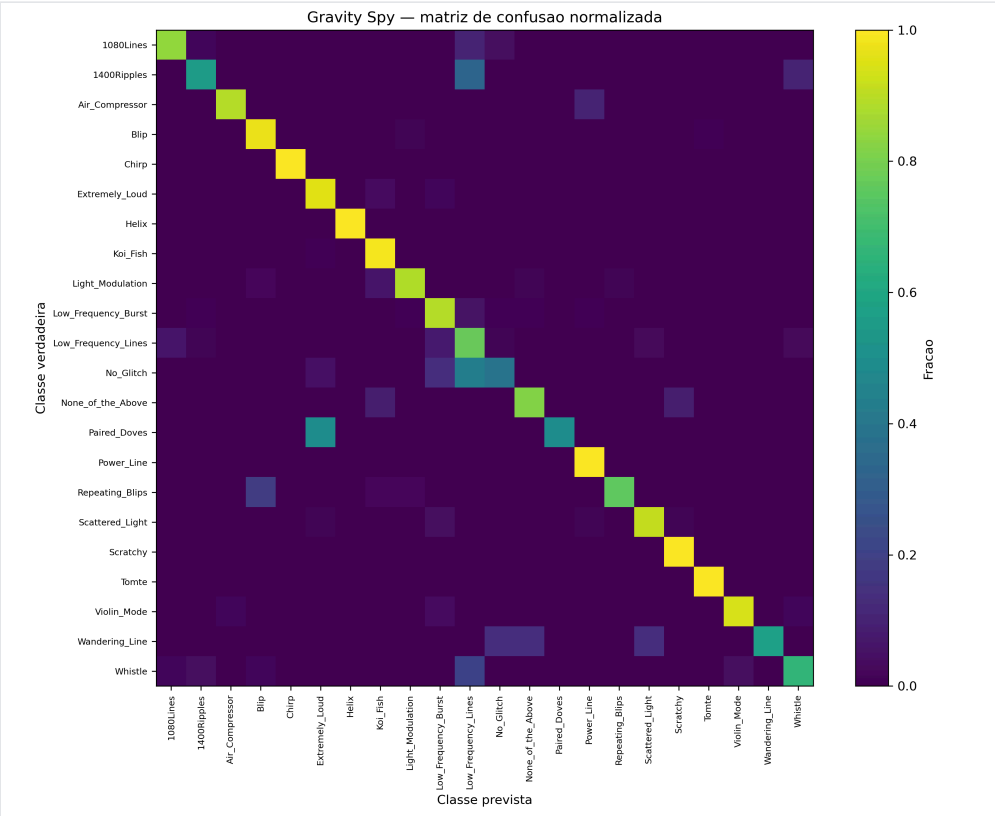


Figura C3 – Seed 71. Macro-F1 0,846 · acurácia 0,904 (teste, 1179 amostras).

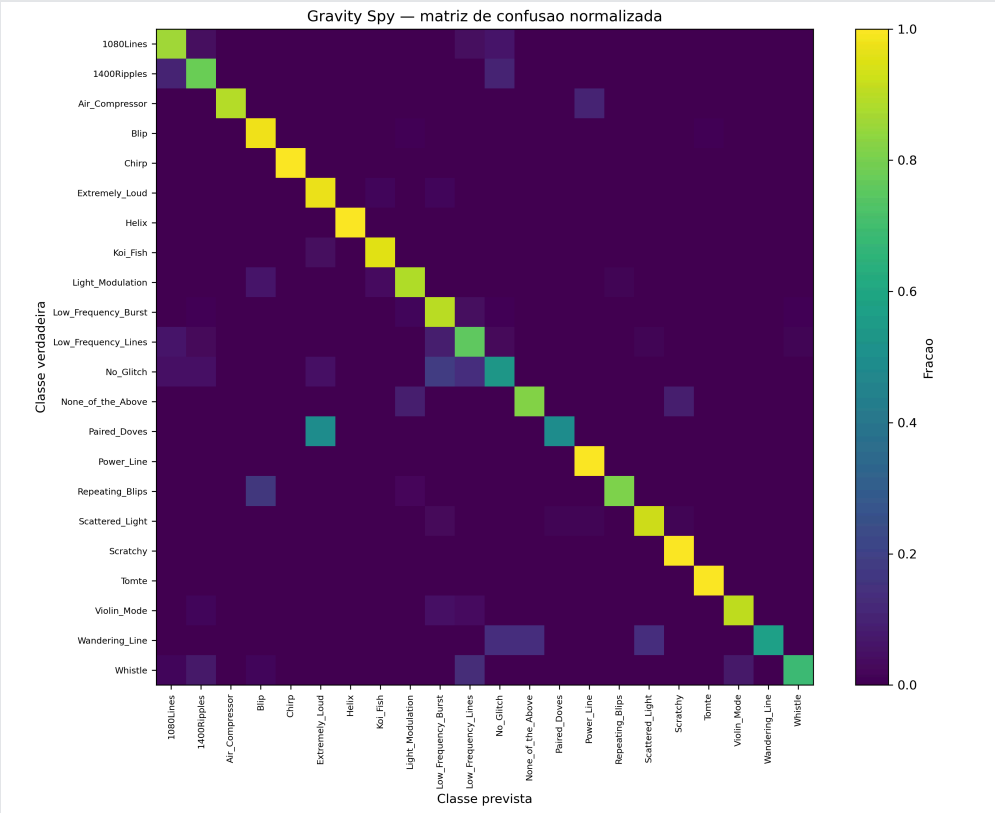


Figura C4 – Seed 101. Macro-F1 0,857 · acurácia 0,911 (teste, 1179 amostras).