RELATÓRIO DE ACOMPANHAMENTO DE PESQUISA CIENTÍFICA · VERSÃO 3

Reprodução independente da linha gwproject 2.0: classificação de glitches e validade externa em 218 eventos do GWTC-4

Projeto 3 – Ondas Gravitacionais · PIC Astronomia · 17 de outubro de 2026

1. Identificação do Projeto

Título do Projeto	Classificação de Glitches em Dados do LIGO com CNNs e Análise de Interpretabilidade (Projeto 3 – Ondas Gravitacionais)
Grupo de Pesquisa	PIC Astronomia
Período Abrangido	10 a 17 de outubro de 2026
Versão / Data	V3 – 17/10/2026. Sucede o Relatório V2 (07/10/2026) e sua errata.
Linha de código	gwproject 2.0 (PR #2, Daniel Tedesco), mesclada em 17/10/2026. A linha anterior (v9) está preservada na branch `v9`.
Repositório	`https://github.com/jean5429/gw-pic-2026`

2. Resumo Executivo

Em 17/10/2026 o projeto adotou a linha gwproject 2.0, que reconstrói o pipeline sobre 218 eventos do catálogo GWTC-4 com controle de qualidade dos dados de treino, treinamento determinístico e referência OOD calibrada por modelo. A linha anterior (v9), base do Relatório V2, tinha três problemas documentados na errata do V2: um painel vazio repetido nos dados Gravity Spy, o limiar OOD calibrado nas mesmas amostras do ajuste e a mistura de modelos no escore OOD.

Este relatório documenta a **reprodução independente e completa** da linha 2.0 em outra máquina (NVIDIA RTX 3060), desde os dados brutos até as análises exploratórias, comparada com os artefatos canônicos registrados em `ARTIFACT_HASHES.sha256`:

- **Dados de treino idênticos:** o controle de qualidade remove os mesmos 159 painéis vazios e produz um `clean_metadata.csv` com SHA-256 idêntico ao canônico (7.807 amostras).
- **Treino reproduzido bit a bit:** os 5 modelos chegam às mesmas métricas até a última casa decimal; o `aggregate_summary.json` tem SHA-256 idêntico ao canônico (macro-F1 de teste 0,9449 ± 0,0092).
- **Referência OOD calibrada:** no teste, 0,4%–1,2% das imagens ficam acima do q99 de Mahalanobis, como no relatório canônico.
- **Catálogo de 218 eventos idêntico em contagem:** 475 canais aprovados, 153 sem dados públicos, 21 rejeitados por não finitude e 5 no branqueamento.
- **Resultado principal reproduzido:** com o renderer canônico, os **475 canais são rejeitados como fora do domínio** Gravity Spy; as classes forçadas diferem do canônico em 1 canal de 475.
- **Experimento exploratório reproduzido:** com a renderização Gravity Spy, a rejeição cai para 54,7% por evento, 17 canais ficam como candidatos em domínio e a fração de Chirp acompanha a SNR (Spearman +0,50), como no canônico.

A conclusão científica da linha 2.0 fica confirmada de forma independente: o classificador treinado nos painéis Gravity Spy **não pode ser usado para classificar os Q-grams GWOSC** com o pipeline canônico. A renderização na escala Gravity Spy reduz a mudança de domínio, mas a rejeição passa a vir do escore de energia, e o efeito permanece exploratório.

3. Contexto: da linha v9 à 2.0

Data	Marco
07/10/2026	Relatório V2: auditoria da linha v9 (orientação dos Q-grams, cores do Grad-CAM, escala de intensidade).
10/10/2026	PR #1 (Daniel Tedesco): correção do filtro casado do kit didático, mesclada. Correção posterior do espectrograma do kit.
10/10/2026	PR #2 (Daniel Tedesco): proposta da linha gwproject 2.0, incorporando as correções da v9 (renderização Gravity Spy, Grad-CAM, anonimização, 300 DPI).
17/10/2026	Merge do PR #2 na `main`; linha v9 preservada na branch `v9`; relatórios mantidos em `docs/relatorios/`.
17/10/2026	Errata do Relatório V2: os três problemas da v9 e seu efeito quantificado (por exemplo, 60 e não 150 de 150 canais acima do limiar OOD com o cálculo corrigido).
17/10/2026	Reprodução independente completa da linha 2.0 (este relatório).

4. Metodologia da Reprodução

Ambiente

Hardware	AMD Ryzen 5 5600G, 32 GB RAM, NVIDIA GeForce RTX 3060 (12 GB)
Software	Windows 11; ambiente conda `gwproject` (Python 3.11.17); PyTorch 2.5.1 + CUDA 12.1 (versão do treino canônico); NumPy 2.4.6, SciPy 1.17.1, pandas 2.3.3 (iguais ao `environment-lock-gpu.yml`); **gwpy 4.1.0** (o arquivo travado indica 4.0.1)
Roteiro	`tools/preparar_passos_1_2.ps1` (ambiente e painéis) e os comandos de `research/GUIA_DE_EXECUCAO.md` (treino, OOD, aquisição, catálogo, ensemble, auditoria e consolidação)

Etapas e tempos

Etapa	Comando principal	Duração
Ambiente e testes (123 aprovados)	`tools/preparar_passos_1_2.ps1`	~40 min
Painéis com controle de qualidade	`gwproject research prepare-panels`	~2 min
Treino das 5 seeds	`gwproject research train-seeds`	1 h 46 min
Referência OOD e controle no teste	`build-ood`, `validate-ood`	~3 min
Aquisição e processamento dos 218 eventos	`gwproject acquire -- --download-strain --process --qgrams`	2 h 45 min
Índice, metadados, ridge, filtro casado, ensemble, auditoria, consolidação	`gwproject catalog …`, `gwproject research …`	~7 min
Renderização exploratória, comparação e Grad-CAM	`classify-ensemble --render-mode gravity_spy`, `compare-ensembles`, `gradcam`	~1 min

5. Resultados

5.1 Dados Gravity Spy com controle de qualidade

Item	Reprodução	Canônico
Registros da metadata oficial	7.966	7.966
Painéis vazios excluídos	159	159
dos quais duplicatas exatas entre divisões	139	139
Amostras limpas (treino / validação / teste)	7.807 (5.472 / 1.177 / 1.158)	7.807 (5.472 / 1.177 / 1.158)
SHA-256 de `clean_metadata.csv` e `qc_summary.json`	idênticos	

5.2 Treino das 5 seeds

Seed	11	23	42	71	101
Macro-F1 de teste	0,9337	0,9390	0,9570	0,9446	0,9503
Melhor época	26	17	19	20	15

Métrica de teste (5 seeds)	Reprodução	Canônico
Macro-F1	0,9449 ± 0,0092	0,9449 ± 0,0092
Acurácia balanceada	0,9459 ± 0,0116	0,9459 ± 0,0116
Kappa	0,9610 ± 0,0041	0,9610 ± 0,0041
Acurácia	0,9648 ± 0,0037	0,9648 ± 0,0037
SHA-256 de `aggregate_summary.json`	idêntico	

Comparado com a linha v9 (macro-F1 0,856, treinada com o painel vazio), o ganho é de cerca de 9 pontos percentuais.

5.3 Referência OOD por modelo (controle no teste)

Imagens de teste acima do limiar (5 modelos)	Reprodução	Canônico	Nominal
Mahalanobis ≥ q95	3,3% – 5,4%	3,4% – 5,4%	5%
Mahalanobis ≥ q99	0,4% – 1,2%	0,4% – 1,2%	1%
Energia ≥ q95 / q99	4,5% – 6,0% / 0,4% – 1,4%	–	5% / 1%

Para comparação, a referência da linha v9 rejeitava 42,3% das imagens de teste no q99 (errata do V2).

5.4 Catálogo de 218 eventos

Item	Reprodução	Canônico
Eventos / combinações evento–detector	218 / 654	218 / 654
Canais aprovados	475	475
Sem dados públicos / não finitos / rejeitados no branqueamento	153 / 21 / 5	153 / 21 / 5
Eventos em rede / com um detector / inutilizáveis	204 / 14 / 0	204 / 14 / 0

5.5 Ensemble com o renderer canônico (percentis)

Resultado (475 canais)	Reprodução	Canônico
`reject_ood` / `review` / `in_domain_candidate`	475 / 0 / 0	475 / 0 / 0
Classes forçadas: None_of_the_Above / Extremely_Loud / Repeating_Blips	243 / 231 / 1	244 / 230 / 1
Excesso de Mahalanobis, log (média por evento)	+1,039	+1,039
Auditoria de atalhos: acurácia balanceada / AUROC (folds por evento)	0,769 / 0,817	0,769 / 0,817

> **Leitura.** Todos os canais excedem o q99 de Mahalanobis em todos os modelos: o classificador não pode ser aplicado aos Q-grams GWOSC renderizados pelo pipeline canônico. A diferença de 1 canal na classe forçada é de um caso de quase empate entre None_of_the_Above e Extremely_Loud, sensível às últimas casas decimais dos Q-grams (seção 6).

5.6 Renderização na escala Gravity Spy (exploratório)

Percentis → Gravity Spy (mesmos canais, modelos e referência)	Reprodução	Canônico
`reject_ood`, média por evento	1,000 → 0,547 (475 → 253)	1,000 → 0,544 (475 → 252)
`review`	0 → 205	0 → 206
`in_domain_candidate`	0 → 17	0 → 17
Mahalanobis acima do q99	475 → 49	475 → 49
Energia acima do q99	0 → 228	0 → 227
Excesso de Mahalanobis (log), mediana por evento	+1,039 → −0,152	+1,039 → −0,153
Confiança fechada do ensemble	0,735 → 0,536	0,735 → 0,536
Classe forçada alterada	464 de 475	464 de 475
Spearman(SNR de rede, fração Chirp) por evento	+0,50	+0,50

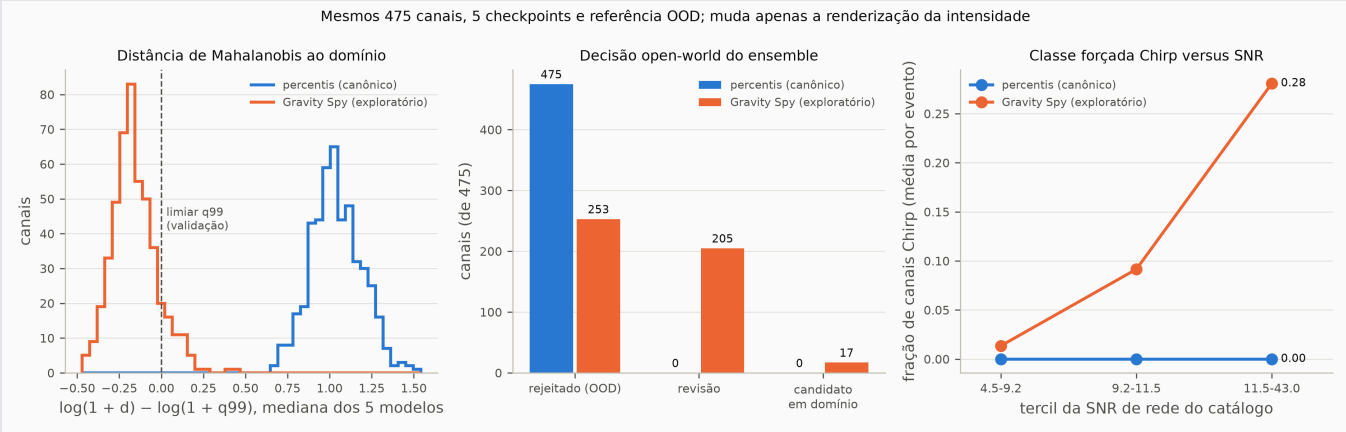


Figura 1 – Efeito da renderização nos 475 canais (reprodução). À esquerda, o excesso de Mahalanobis passa de todo acima do limiar q99 para, na mediana, abaixo dele. No centro, a decisão open-world. À direita, a fração de canais forçados para Chirp cresce com a SNR de rede apenas na renderização Gravity Spy.

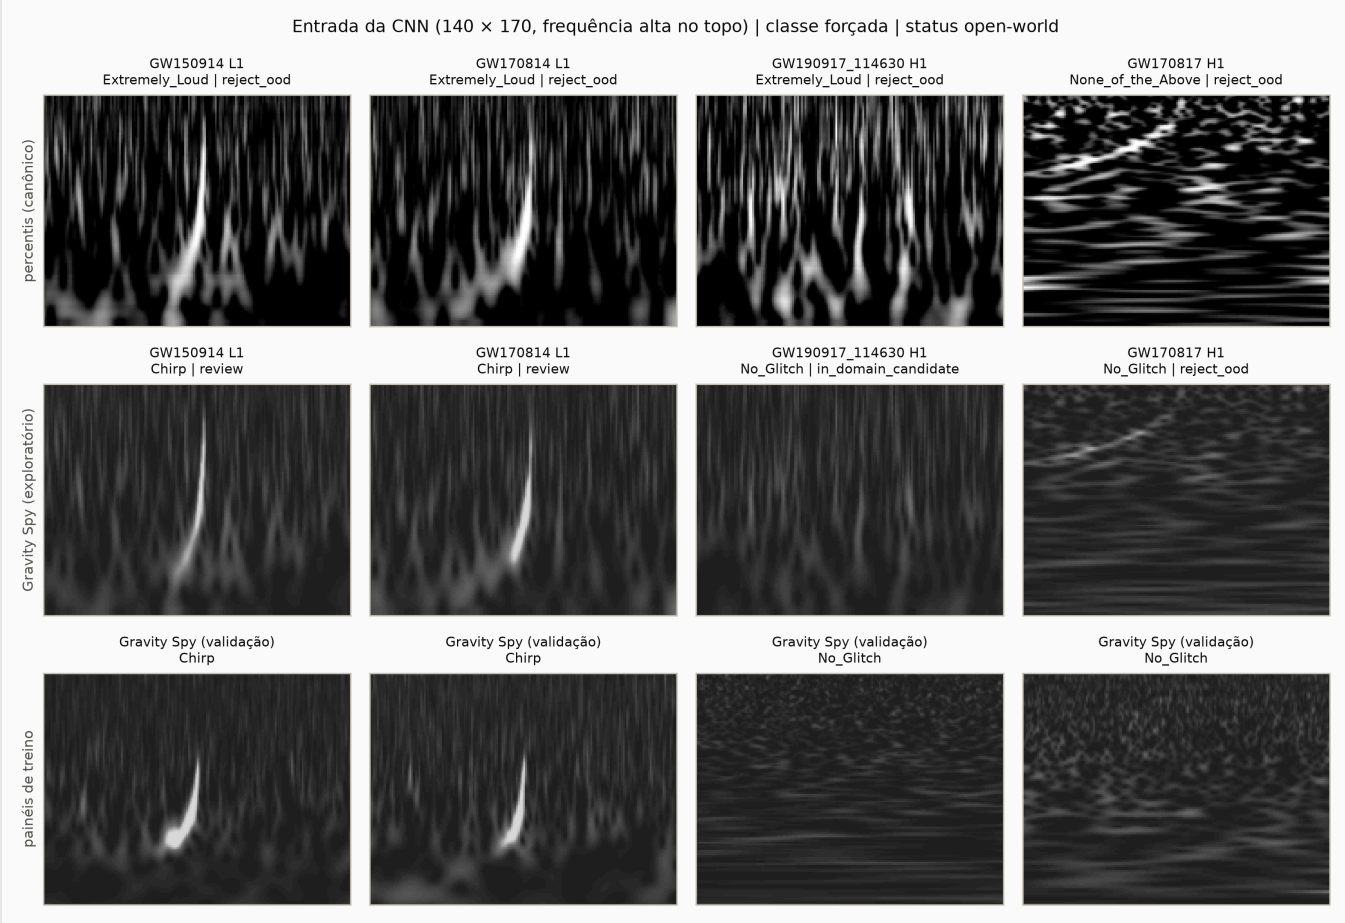


Figura 2 – Entradas da CNN nos dois renderizadores e painéis de validação do Gravity Spy (reprodução). A escala 0–25,5 em viridis reproduz o fundo cinza dos painéis de treino; o renderer por percentis leva o fundo ao preto.

> **Cautela.** O resultado é exploratório e não preregistrado. A rejeição agregada cai porque a distância de Mahalanobis se aproxima do domínio, mas o escore de energia passa a rejeitar 228 canais: os dois escores andam em sentidos opostos, e essa discordância está em aberto.

5.7 Grad-CAM do GW150914 (L1, seed 42)

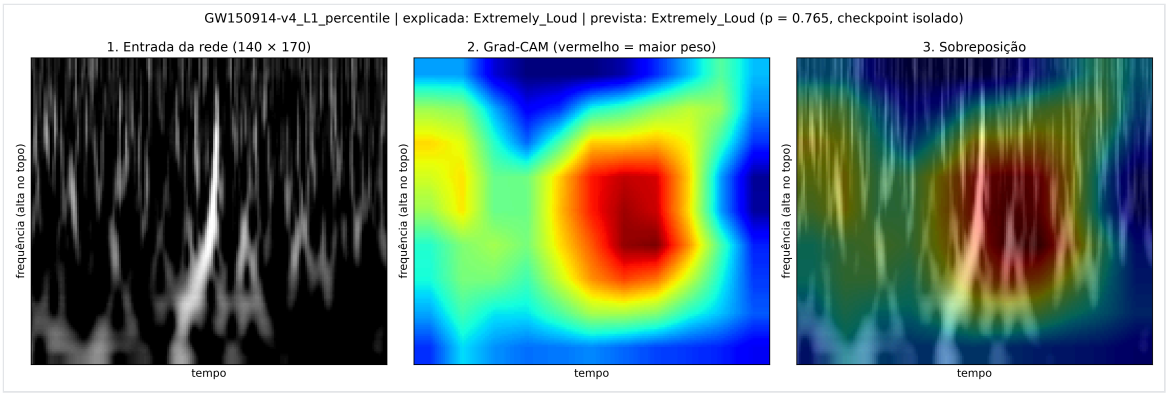


Figura 3 – Renderer canônico (percentis): o checkpoint isolado prevê Extremely_Loud.

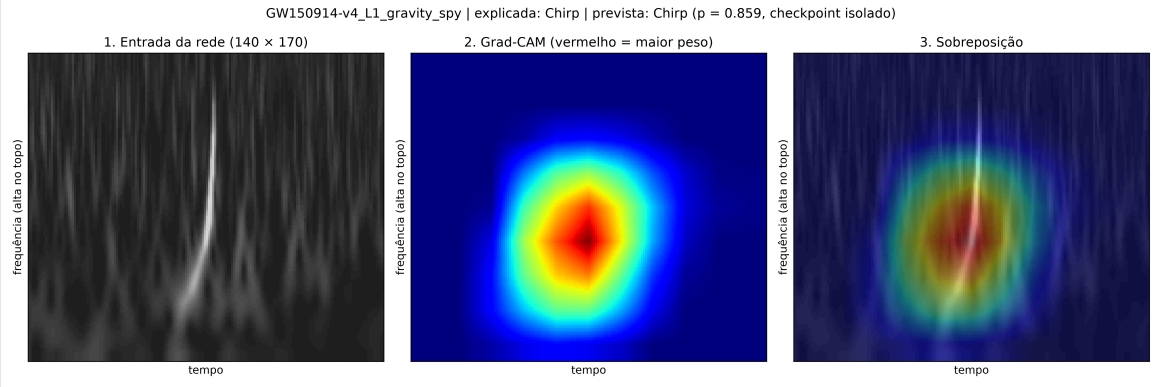


Figura 4 – Renderização Gravity Spy: prevê Chirp (p = 0,859), com a atenção máxima sobre a trilha do sinal.

5.8 Diagnósticos condicionados ao catálogo

Ridge (475 canais)	Reprodução = Canônico
Ajustes aceitos	201
Eventos com estimativa em rede / em um detector / sem estimativa	75 / 40 / 103
Erro relativo contra o catálogo condicionante: mediana / média / p90	34,7% / 40,1% / 78,8%

Filtro casado local (218 eventos)	Reprodução = Canônico
Análise concluída / sem template ativo / sem massas no referencial do detector	164 / 12 / 42
Template central vencedor / SNR local acima do limiar / margem top-2 / coincidência	9 / 61 / 65 / 34
Gates diagnósticos locais / gate completo	7 / 0

Ridge e filtro casado continuam sendo diagnósticos condicionados ao catálogo: não sustentam medição cega de massa, detecção nem taxa de falso alarme.

6. Conferência com os Artefatos Canônicos

Artefato	SHA-256	Observação
`data/gravity_spy_harmonized/clean_metadata.csv`, `qc_summary.json`	idênticos	Mesma base de treino.
`models/…/aggregate_summary.json`	idêntico	Treino determinístico reproduzido bit a bit.
`outputs/gwtc4_218/catalog_dataset_summary.json`	idêntico	Mesmo conjunto de canais.
Ridge: `diagnostic_summary.json`, `per_event.csv`; filtro casado: `summary.json`	idênticos	Mesmos diagnósticos.
`catalog.csv`, `approved_channels.csv`, `event_quality_summary.csv`, `run_log.json`	diferentes	Valores em ponto flutuante do processamento (gwpy 4.1.0 contra 4.0.1), metadados GWOSC atualizados e caminhos locais; contagens idênticas.
Referência OOD (`.npz`, `.json`) e controle no teste	diferentes	Arquivos zip com data de criação e registros de horário; taxas no teste compatíveis (5.3).
Ensemble, estatísticas renderizadas, auditoria de domínio, tabela dos 218 eventos, ridge e filtro casado por canal/evento	diferentes	Propagam as diferenças numéricas dos Q-grams; resultados agregados iguais, com no máximo 1 canal de diferença.

De 24 artefatos comparáveis, 7 são idênticos byte a byte; os demais diferem por fatores conhecidos e não científicos. Para uma reprodução byte a byte da etapa de aquisição, o ambiente deveria fixar o `gwpy` em 4.0.1 (seção 9).

7. Problemas Encontrados e Correções

- **`igwn-segments` no Windows:** no PyPI só existe como código-fonte e exige compilador C; o `environment.yml` passou a instalá-lo pelo conda-forge.
- **Versão do `gwpy` não fixada:** o `environment.yml` instalou a 4.1.0, enquanto o canônico usou a 4.0.1. É a causa provável das diferenças numéricas da seção 6.
- **Execução de scripts no PowerShell:** a política do Windows bloqueia o perfil que carrega o conda; o roteiro foi executado com o conda adicionado ao caminho apenas no processo.
- **Kit didático:** a correção do espectrograma (normalização pela mediana) foi trazida para a linha 2.0.

8. Estado Atual da Pesquisa

Item	Status	Observações
Linha gwproject 2.0 adotada	Concluído	Merge do PR #2; v9 na branch `v9`.
Errata do Relatório V2	Concluído	`docs/relatorios/Errata_Relatorio_V2.pdf`.
Reprodução independente da linha 2.0	Concluído	Dados e treino idênticos; resultados agregados reproduzidos.
Validade externa no GWTC-4	Resultado negativo confirmado	475/475 canais fora do domínio com o renderer canônico.
Renderização Gravity Spy	Exploratório	Reduz a distância de Mahalanobis; discordância com a energia em aberto.
Redação científica	Pendente	Depende da decisão sobre o renderer e das questões da seção 9.

9. Próximos Passos

- **Fixar o `gwpy` 4.0.1** no `environment.yml` e, se desejado, repetir a aquisição para reprodução byte a byte dos artefatos de catálogo.
- **Discordância entre energia e Mahalanobis** na renderização Gravity Spy (explicação E4 do `research/PARECER_CIENTIFICO_E_ROTEIRO.md`): entender por que a distância se aproxima do domínio enquanto a confiança cai.
- **Preregistrar** a renderização Gravity Spy como hipótese confirmatória, se o grupo decidir seguir por ela, e definir o critério de "em domínio".
- **Examinar os 17 candidatos em domínio** (todos No_Glitch, SNR de rede entre 7,6 e 14,5, 4 do Virgo) e os canais forçados para Chirp nos eventos mais intensos.
- **Controles negativos (off-source)** com o mesmo pipeline, para medir a taxa de cada decisão sem sinal.

10. Pendências para a Reunião do Grupo

- [ ] Apresentar ao professor a reprodução bit a bit do treino e das contagens do catálogo.
- [ ] Decidir se o `gwpy` é fixado em 4.0.1 e a aquisição repetida.
- [ ] Decidir o status da renderização Gravity Spy (exploratória ou preregistrada).
- [ ] Definir o escopo do primeiro texto científico a partir do resultado negativo de validade externa.

11. Conclusão

A linha gwproject 2.0 foi reproduzida de forma independente, do download dos dados ao relatório: a base de treino e o treino dos cinco modelos são idênticos aos canônicos, a referência OOD está calibrada, e o catálogo de 218 eventos, o ensemble, a auditoria de domínio e os diagnósticos de ridge e filtro casado reproduzem os resultados publicados, com diferenças de no máximo um canal atribuíveis a uma versão diferente do `gwpy`. Isso confirma tanto a reprodutibilidade do pipeline quanto o resultado principal: com o pipeline canônico, os Q-grams dos eventos GWTC-4 estão fora do domínio do classificador Gravity Spy. A renderização na escala Gravity Spy reduz essa distância e faz a classe Chirp acompanhar a SNR, mas permanece exploratória enquanto a discordância entre os escores OOD não for entendida.

Anexo A – Comandos da Reprodução

Na raiz do repositório, com o ambiente `gwproject` ativo e `CUBLAS_WORKSPACE_CONFIG=:4096:8`:

`& .\tools\preparar_passos_1_2.ps1`

`gwproject research train-seeds .\data\gravity_spy_harmonized\clean_metadata.csv .\data\gravity_spy_harmonized --profile cuda_balanced --output-dir .\models\gravity_spy_harmonized_v1d1`

`gwproject research aggregate-seeds .\models\gravity_spy_harmonized_v1d1`

`gwproject research build-ood .\models\gravity_spy_harmonized_v1d1 --metadata .\data\gravity_spy_harmonized\clean_metadata.csv --images-root .\data\gravity_spy_harmonized --device cuda --output .\outputs\research\gwtc4_218\ood_reference.npz`

`gwproject research validate-ood .\outputs\research\gwtc4_218\ood_reference.npz --metadata … --images-root … --device cuda --output .\outputs\research\gwtc4_218\ood_test_control.json`

`gwproject acquire -- --download-strain --process --qgrams`

`gwproject catalog index` · `gwproject catalog refresh-metadata -- --workers 4`

`gwproject catalog ridge -- --workers 2 --no-resume` · `gwproject catalog matched-filter -- --workers 1 --no-resume` · `gwproject catalog diagnose-ridge`

`gwproject research classify-ensemble .\models\gravity_spy_harmonized_v1d1 --ood-reference … --device cuda --output-dir .\outputs\research\gwtc4_218\gravity_spy_ensemble`

`gwproject research catalog-statistics …` · `audit-domain …` · `consolidate-events … --expected-events 218`

`gwproject research classify-ensemble … --render-mode gravity_spy --output-dir .\outputs\research\renderer_gravity_spy_20261017\ensemble_gravity_spy`

`gwproject research compare-ensembles … --output-dir .\outputs\research\renderer_gravity_spy_20261017\comparacao`

`gwproject research gradcam --event GW150914-v4 --detector L1 --render-mode gravity_spy`

Figuras 1 e 2 geradas por `research/figures/renderizador_gravity_spy_figuras.py` a partir das execuções desta reprodução; as saídas completas ficam em `outputs/` e `models/`, fora do versionamento.